2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Integrantes Grupo 17:

- Benini Gonzalo David
- Lozano Francisco
- Rezola Tomas Ezequiel

Índice

1. Introducción **2**
2. Comportamiento del dataset **2**
3. Distribución de variables **10**
4. Análisis de variables numéricas **12**
5. Limpieza de la base de datos **19**
6 Transformación y codificación de variables **26**
6.1 Renombrado de categorías y agrupación visual 26
6.2 Desagregación de preguntas de selección múltiple 27
7. Reducción de dimensionalidad **29**
7.1 Preparación de los datos **29**
7.2 Técnicas utilizadas **30**
7.3 Análisis 1: Estructura respecto de los años de experiencia laboral **30**
7.4. Análisis 2: Estructura respecto de la remuneración anual **34**
7.5. Conclusiones **36**
8. Planteo y validación de hipótesis **37**
9. Conclusión **51**

1. Introducción

La Encuesta para Desarrolladores de 2025 de Stack Overflow es un conjunto de datos que busca representar el estado actual del desarrollo de software a partir de las respuestas de desarrolladores de distintos países. La encuesta recibió más de 49.000 respuestas provenientes de 177 países y abarcó preguntas relacionadas con la experiencia profesional, las tecnologías utilizadas, la satisfacción laboral y el uso de herramientas de Inteligencia Artificial, entre otros aspectos.

A partir de este conjunto de datos, realizaremos un análisis exploratorio con el objetivo de conocer sus características, comprender la distribución de sus variables y detectar posibles relaciones entre ellas. Para esto, se analizarán aspectos como la experiencia laboral y en programación, la remuneración, la satisfacción con el trabajo y diferentes variables relacionadas con el uso, confianza y percepción de la Inteligencia Artificial.

Como parte del proceso, también se realizará una etapa de limpieza y preparación de los datos, tomando decisiones sobre las variables que resulten adecuadas para el análisis. Se considerarán aspectos como los valores nulos, los datos duplicados y las características de las variables, buscando reducir el conjunto de datos a la información relevante para los objetivos planteados.

Finalmente, a partir de los resultados obtenidos durante el análisis exploratorio, se plantearán y contrastarán diferentes hipótesis sobre las características de los desarrolladores y su relación con la Inteligencia Artificial, utilizando herramientas de análisis estadístico para determinar qué relaciones o diferencias encuentran sustento en los datos.

2. Comportamiento del dataset

Luego de realizar una primera exploración del conjunto de datos, buscamos identificar qué información contiene, cómo se encuentran organizadas sus variables y qué características presentan. El dataset cuenta con más de 49.000 respuestas de desarrolladores y, luego de las decisiones tomadas durante el proceso de limpieza, se trabajó con 114 variables para el análisis.

Para facilitar su interpretación, agrupamos las variables según el tipo de información que representan. De esta manera, podemos distinguir cinco grandes grupos: **demografía y perfil laboral, experiencia y aprendizaje, criterios de evaluación tecnológica y satisfacción, stack tecnológico y herramientas, inteligencia artificial y agentes autónomos**.

Demografía y perfil laboral

Este grupo reúne información relacionada con las características generales de los encuestados y su situación laboral. Algunas de las variables más importantes son:

- **MainBranch**: Indica si el encuestado escribe código profesionalmente, como estudiante o por hobby. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **Age**: Edad del encuestado. Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **Country**: País de residencia. Variable de múltiple respuesta de naturaleza cualitativa nominal.
- **Currency**: Moneda utilizada en su día a día. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **CompTotal**: Compensación económica total anual (salario, bonos, etc.). Variable de respuesta libre de naturaleza cuantitativa continua.

- **EdLevel**: Nivel más alto de educación formal completada. Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **Employment**: Situación laboral actual (ej. empleado a tiempo completo, estudiante). Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **EmploymentAddl**: Actividades adicionales (ej. trabajador independiente/freelance). Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **Industry**: Sector o industria en la que trabaja. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **OrgSize**: Tamaño de la empresa (cantidad de empleados). Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **DevType**: Rol principal o puesto de trabajo (ej. Desarrollador Frontend, Backend). Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **ICorPM**: Clasifica si es un colaborador individual (Individual Contributor) o un gestor de personas (People Manager). Variable de múltiple respuesta de naturaleza cualitativa nominal dicotómica.

- **RemoteWork**: Modalidad de trabajo actual (Remoto, presencial, híbrido). Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **JobSat**: Nivel de satisfacción en su rol actual. Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **NewRole**: Indica si ha considerado cambiar de carrera o buscar un nuevo rol en el último año. Variable de múltiple respuesta de naturaleza cualitativa nominal.

Estas variables permiten caracterizar a los participantes y establecer posteriormente posibles relaciones entre sus características personales o laborales y otros aspectos analizados en el trabajo, como la experiencia, la remuneración o la percepción de la inteligencia artificial.

Experiencia y aprendizaje

En este grupo se encuentran las variables relacionadas con la experiencia profesional y con las formas en que los desarrolladores adquieren nuevos conocimientos.

- **WorkExp**: Años de experiencia laboral profesional. Variable de respuesta libre de naturaleza cuantitativa discreta.

- **YearsCode**: Años totales programando (incluyendo etapa educativa). Variable de respuesta libre de naturaleza cuantitativa discreta.

- **LearnCodeChoose**: ¿Comenzó a aprender a programar o aprendió una nueva habilidad en el último año? Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **LearnCode**: Métodos o recursos utilizados para aprender a programar. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **LearnCodeAI**: ¿Dedicó tiempo a aprender programación de IA o herramientas de IA este año? Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AILearnHow**: Métodos utilizados específicamente para aprender a programar para IA. Variable de múltiple respuesta de naturaleza cualitativa nominal.

Estas variables permiten estudiar la relación entre la experiencia de los desarrolladores, sus formas de aprendizaje y su incorporación de conocimientos relacionados con inteligencia artificial.

Criterios de evaluación tecnológica y satisfacción

Este grupo reúne variables relacionadas con los factores que influyen en la elección de tecnologías y con los aspectos que contribuyen a la satisfacción laboral.

- **TechEndorse_[1-13]**: Ranking donde el encuestado responde que factores le atraen o hacen que recomiende una tecnología (ej. Integración con IA, API fácil de usar, código manejable, reputación). Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **TechOppose_[1-15]**: Ranking donde el encuestado responde que factores le causan rechazo hacia una tecnología (ej. Falta de IA, mala usabilidad, precios altos, preocupaciones de seguridad). Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **JobSatPoints_[1-11] y JobSatPoints_[13-16]**: Ranking de atributos que más contribuyen a su satisfacción laboral (ej. Control de calidad, autonomía, relación con el manager, mentores). Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **ToolCountWork**: Cantidad de herramientas/software distintas que usa regularmente para su trabajo principal. Variable de respuesta libre de naturaleza cuantitativa discreta.

- **ToolCountPersonal**: Cantidad de herramientas/software distintas que usa regularmente para proyectos personales. Variable de respuesta libre de naturaleza cuantitativa discreta.

Stack tecnológico y herramientas

Este grupo contiene información sobre las tecnologías utilizadas actualmente por los encuestados y aquellas que tienen intención de utilizar en el futuro.

La estructura se repite para distintas categorías tecnológicas. Por ejemplo, existen variables relacionadas con:

- **Language[...]**: Se basa en consultar qué herramientas de lenguajes usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **Database[...]**: Se basa en consultar qué entornos de bases de datos usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.
- **Platform[...]**: Se basa en consultar qué herramientas de construcción o infraestructura usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **Webframe[...]**: Se basa en consultar qué frameworks o tecnologías web usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **DevEnvs[...]**: Se basa en consultar qué entornos de desarrollo o herramientas de edición de código mediante IA usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **OpSys**: Sistema operativo principal de uso profesional o personal del encuestado. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **OfficeStackAsync[...]**: Se basa en consultar qué herramientas de trabajo colaborativo o documentación de código usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **CommPlatform[...]**: Se basa en consultar qué plataformas de comunicación usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

- **AIModels[...]**: Se basa en consultar qué modelos LLM específicos integrados en sus herramientas usó el encuestado el año pasado o desea usar en el año que viene. Variables de múltiple respuesta de naturaleza cualitativa nominal.

En varias de estas categorías se diferencia entre las tecnologías utilizadas durante el último año y aquellas que el encuestado desea utilizar durante el próximo año. Esto permite no solamente conocer el estado actual del stack tecnológico de los desarrolladores, sino también observar sus preferencias y posibles tendencias futuras.

Inteligencia Artificial y agentes autónomos

Por último, el dataset contiene un grupo específico de variables destinado a analizar la relación entre los desarrolladores y la inteligencia artificial. Esta parte resulta especialmente relevante para nuestro análisis debido a la incorporación de nuevas preguntas relacionadas con herramientas de IA y agentes autónomos.

Entre las principales variables encontramos:

- **AIThreat**: ¿Cree que la IA representa una amenaza para su trabajo actual? Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AISelect**: ¿Usa herramientas de IA actualmente en su proceso de desarrollo? Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **AISent**: Postura (favorable/desfavorable) sobre el uso de IA en su flujo de trabajo. Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **AIAcc**: Nivel de confianza en la precisión de los resultados que da la IA. Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **AIComplex**: ¿Qué tan bien manejan tareas complejas las herramientas de IA que usa? Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **AITool**: Áreas específicas de su flujo de trabajo donde usa o planea integrar IA en los próximos 3-5 años. Se presenta una matriz con filas dadas por flujos de trabajo y columnas por uso actual o pensado de IA en ese ámbito, siendo una única opción posible por fila. Variables de única respuesta de naturaleza cualitativa nominal.

- **AIFrustration**: Problemas o frustraciones comunes al usar herramientas de IA. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIAgents**: ¿Utiliza "Agentes de IA" autónomos en su trabajo? Variable de múltiple respuesta de naturaleza cualitativa ordinal.

- **AIAgentChange**: ¿Los agentes o herramientas de IA han cambiado su forma de trabajar este año? Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIAgent_Uses**: Casos de uso específicos o tareas en la industria donde aplica agentes de IA. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIAgentImpact**: Impacto percibido de los agentes de IA en su trabajo. Se basa en situaciones de mejora a través del uso de agentes como filas y columnas dadas por el nivel de acuerdo o desacuerdo por parte del encuestado. Cada columna es una variable y estas son de única respuesta de naturaleza cualitativa nominal.

- **AIAgentChallenges**: Desafíos principales al interactuar o desarrollar agentes de IA. Se basa en situaciones de preocupación por el uso de agentes como filas y columnas dadas por el nivel de acuerdo o desacuerdo por parte del encuestado. Cada columna es una variable y estas son de única respuesta de naturaleza cualitativa nominal.

- **AIAgentKnowledge**: Herramientas usadas para la gestión de memoria/datos de los agentes de IA en el último año. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIAgentOrchestration**: Herramientas y frameworks utilizados para la orquestación de agentes (ej. LangChain, AutoGPT). Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIAgentObserveSecure**: Herramientas para el monitoreo, observabilidad y seguridad de los agentes de IA. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIAgentExternal**: Agentes, copilotos o asistentes out-of-the-box (preconfigurados) que utiliza. Variable de múltiple respuesta de naturaleza cualitativa nominal.

- **AIHuman**: Situaciones en las que, incluso si la IA mejora, preferiría pedirle ayuda a un ser humano. Variable de múltiple respuesta de naturaleza cualitativa nominal.

En conjunto, estas variables permiten analizar diferentes dimensiones de la relación entre los desarrolladores y la inteligencia artificial: desde su utilización y confianza hasta las dificultades, beneficios percibidos y cambios producidos en la forma de trabajar.

Tipos de variables

Además de agrupar las variables según el tipo de información que representan, el esquema de metadatos proporcionado para el dataset permite identificar diferentes formas en las que se obtuvieron las respuestas.

Las principales categorías que identificamos son:

- **RO (Rank Order)**: preguntas en las que el encuestado debe ordenar distintas características según un criterio determinado. En el dataset, cada elemento del ranking se representa mediante una columna numérica. Por ejemplo, un valor 1 representa una posición superior a un valor 2.

- **MC (Multiple Choice)**: preguntas en las que el encuestado debe seleccionar una o más opciones entre las disponibles.

- **TE (Text Entry)**: campos de respuesta libre en los que el encuestado puede introducir un valor que no se encuentra entre las opciones proporcionadas o desarrollar una respuesta.

- **Matrix**: preguntas que combinan dos dimensiones sobre un mismo conjunto de elementos. Por ejemplo, en la pregunta sobre lenguajes de programación se consulta tanto qué lenguajes fueron utilizados durante el último año como cuáles se desea utilizar durante el próximo año.
-



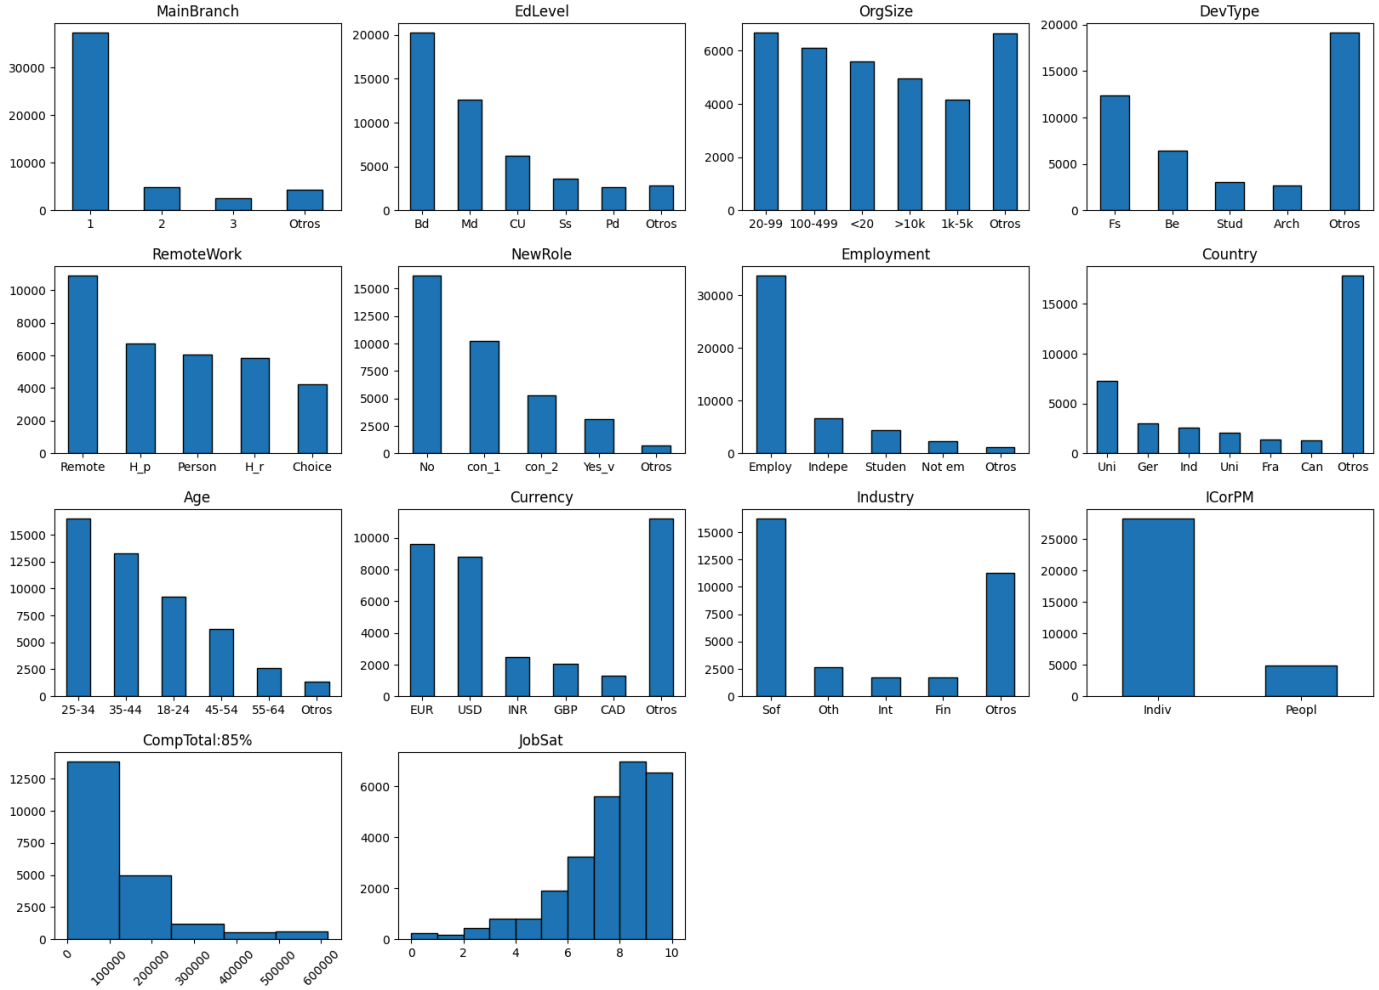
La utilización de estos distintos tipos de preguntas hace que el dataset tenga variables con características diferentes. Algunas representan valores numéricos, otras categorías, rankings o selecciones múltiples. Por este motivo, antes de realizar los análisis estadísticos fue necesario tener en cuenta la naturaleza de cada variable y no tratar todas las columnas de la misma manera.

Esta clasificación inicial también permite entender las decisiones tomadas posteriormente durante la limpieza de los datos. En particular, algunas variables de respuesta libre, variables relacionadas exclusivamente con el uso de Stack Overflow y variables asociadas a la compra de tecnología no resultaron relevantes para el objetivo de nuestro análisis. Estas decisiones se explican con mayor detalle en la sección 5. Limpieza de la base de datos.

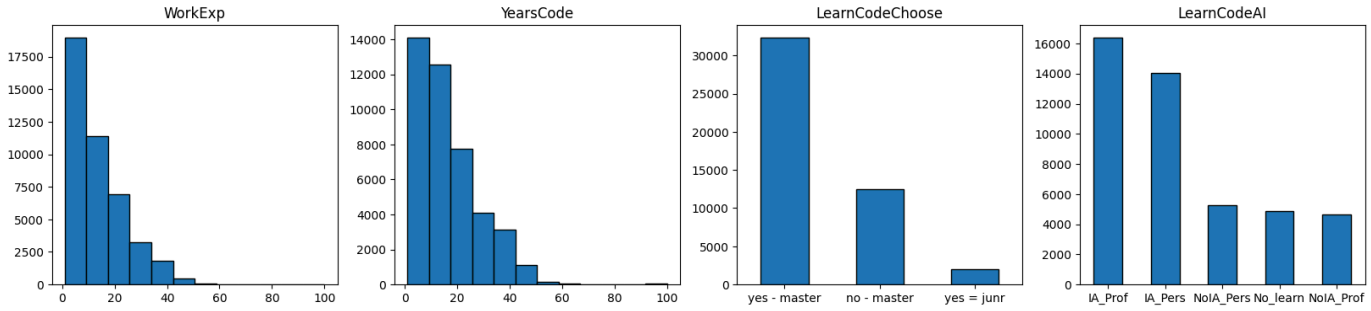
3. Distribución de variables

En este apartado se tiene por objetivo describir visualmente la distribución de las variables como primer vistazo general. Además, para permitir entender mejor los datos, se presentan los gráficos de variables limitadas a percentiles específicos indicados en su nombre debido a que presentan valores *outliers* que sesgan la distribución.

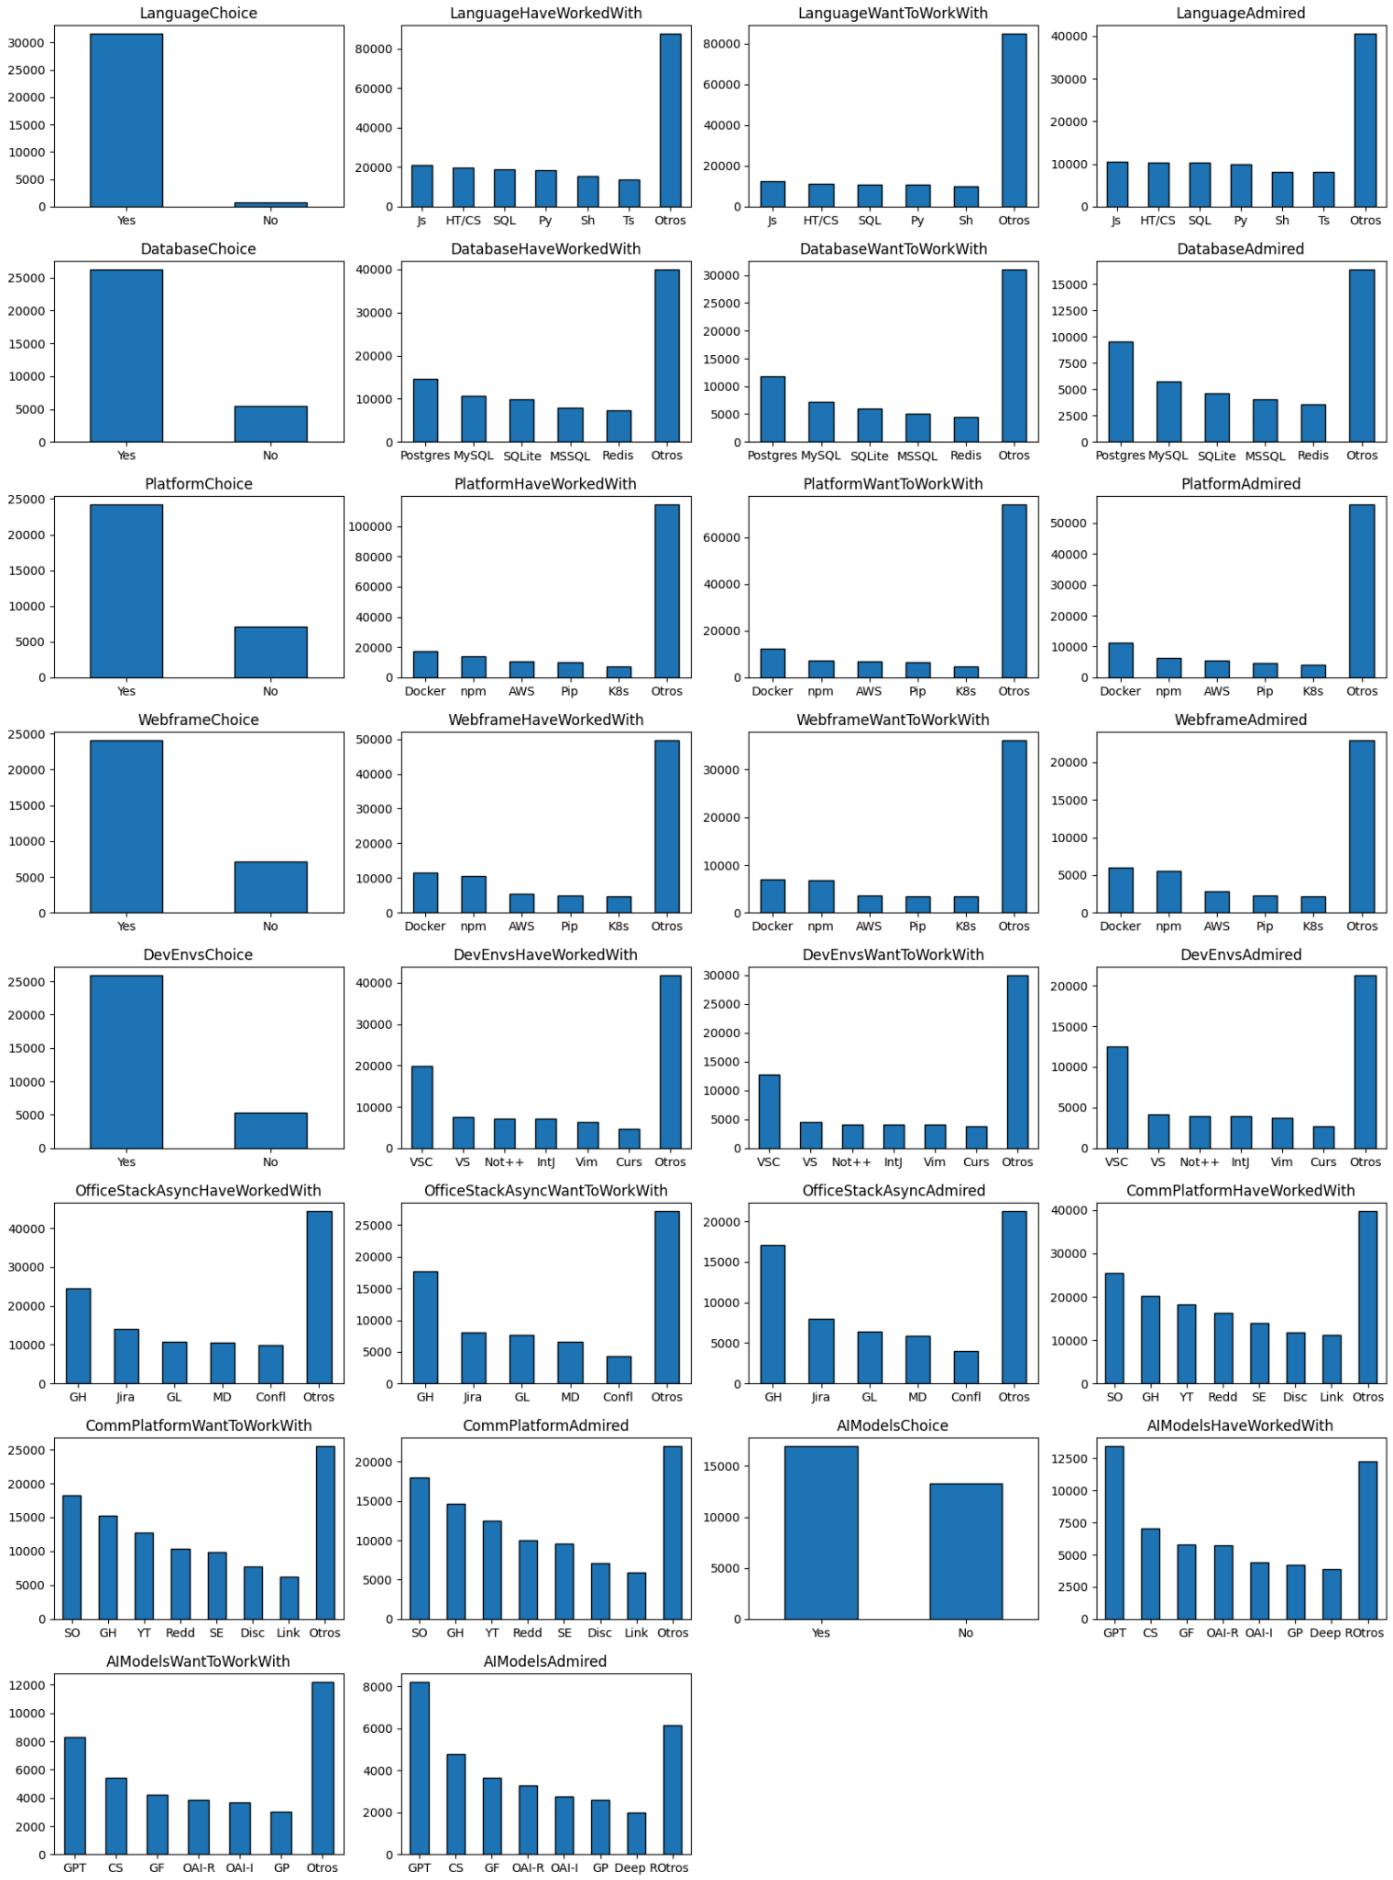
- **Demografía y Perfil Laboral**



- **Experiencia y Aprendizaje**



- **Stack Tecnológico y Herramienta**



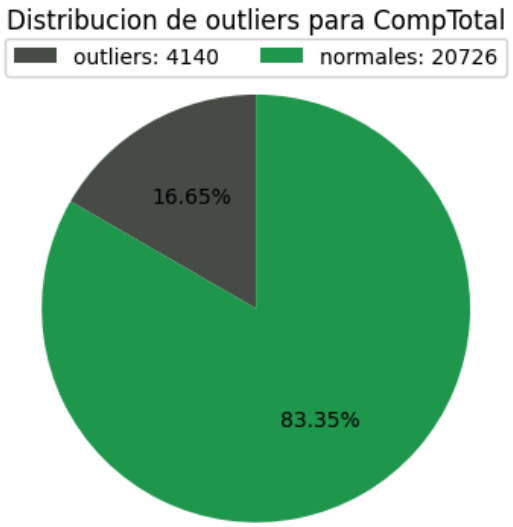
4. Análisis de variables numéricas

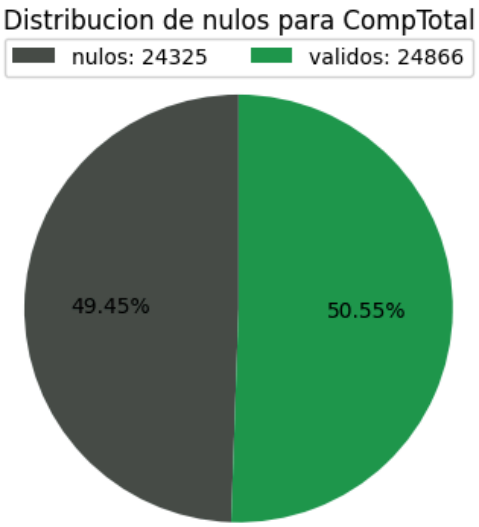
- **CompTotal**

  Observando la distribución de la variable mediante un *box plot* observamos que teníamos una cantidad tan grande de *outliers* que no podíamos visualizar la 'caja' del gráfico.

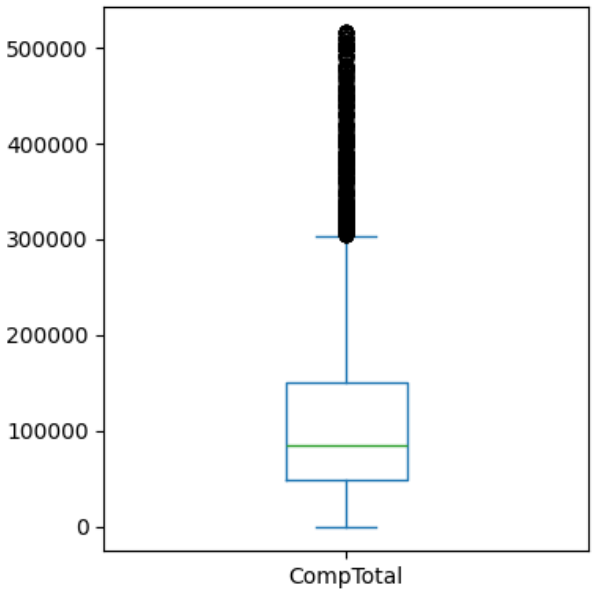
  ¿Por qué ocurre esto en el contexto del problema?

  La variable *CompTotal* se trata de la compensación total anual que obtuvo el encuestado en su moneda del día a día (*Currency*). Así, tenemos múltiples monedas donde claramente las escalas de las mismas son totalmente diferentes (por ejemplo, el valor del **peso argentino** o del **yuan** se diferencia notoriamente del **dólar estadounidense**) y sus valores no son directamente comparables.

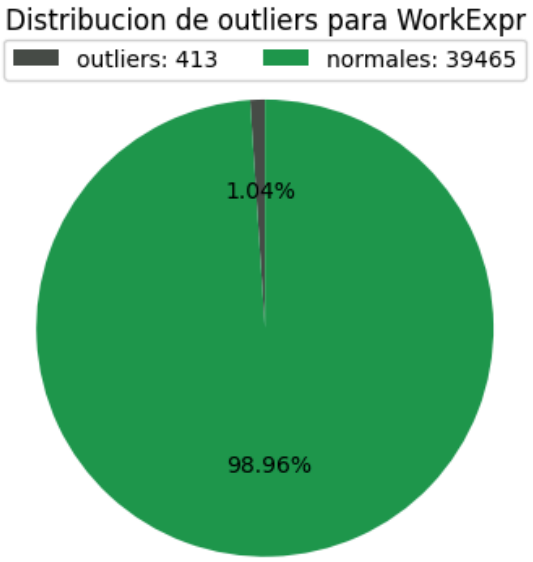


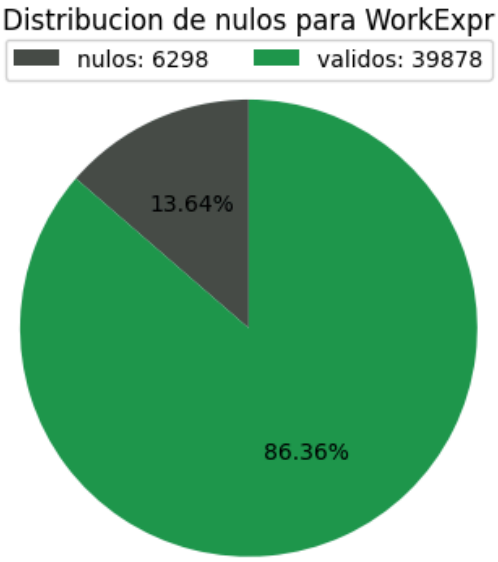


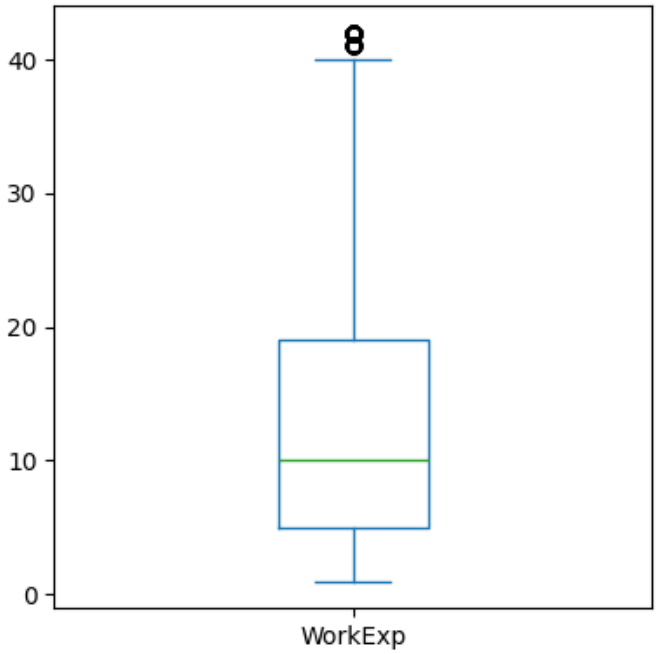
Eliminado esta primera iteración de *outliers* y volviendo a obtener el *boxplot*, observamos



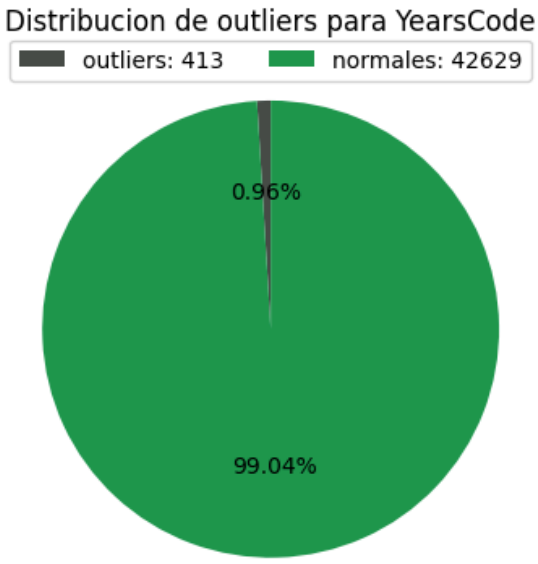
- **WorkExp**

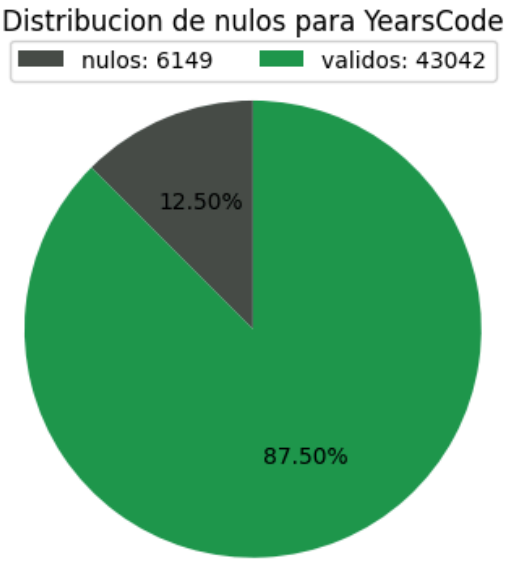

Distribucion de outliers para WorkExpr
outliers: 413
normales: 39465
1.04%
98.96%

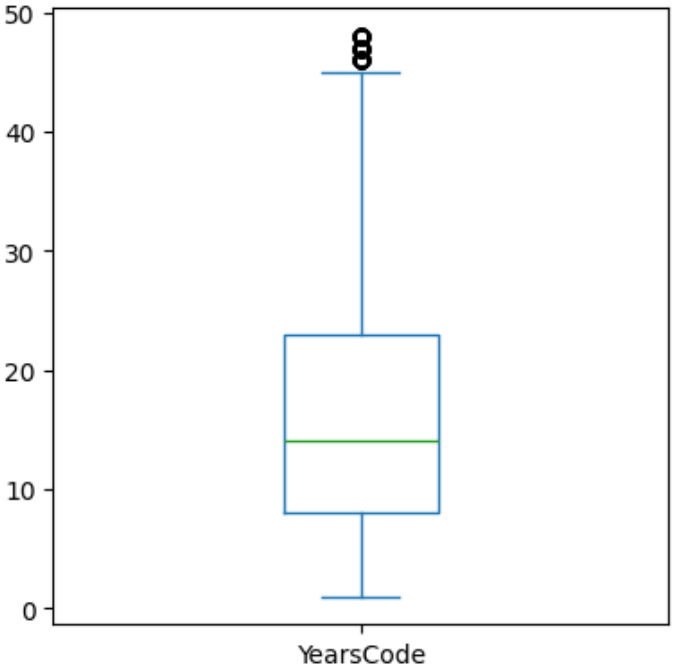

Distribucion de nulos para WorkExpr
nulos: 6298
validos: 39878
13.64%
86.36%


40
30
20
10
0
WorkExp

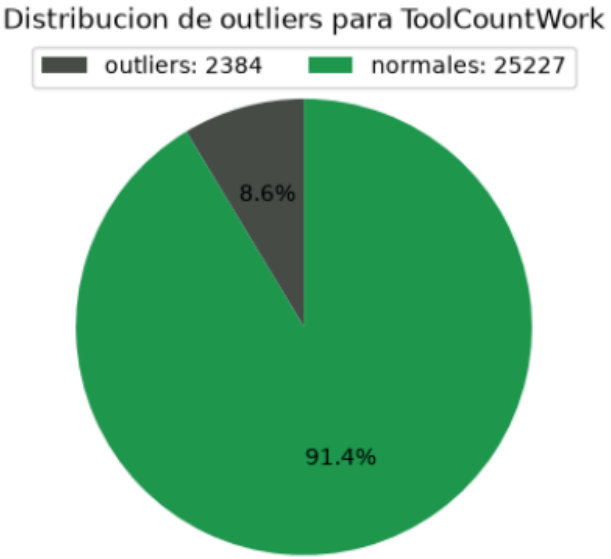
- **YearsCode**

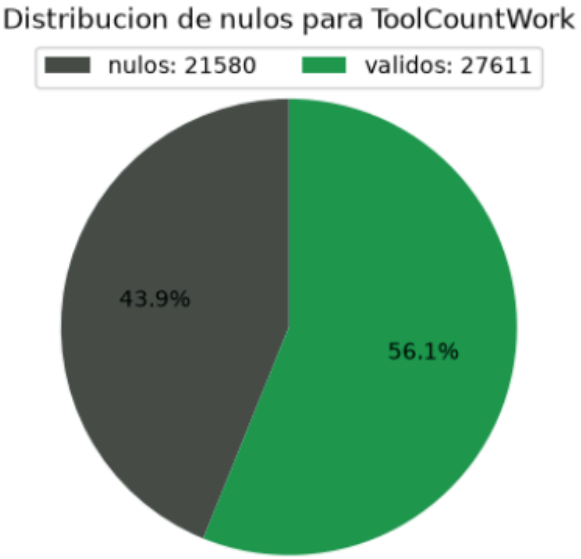

Distribucion de outliers para YearsCode
outliers: 413
normales: 42629
0.96%
99.04%

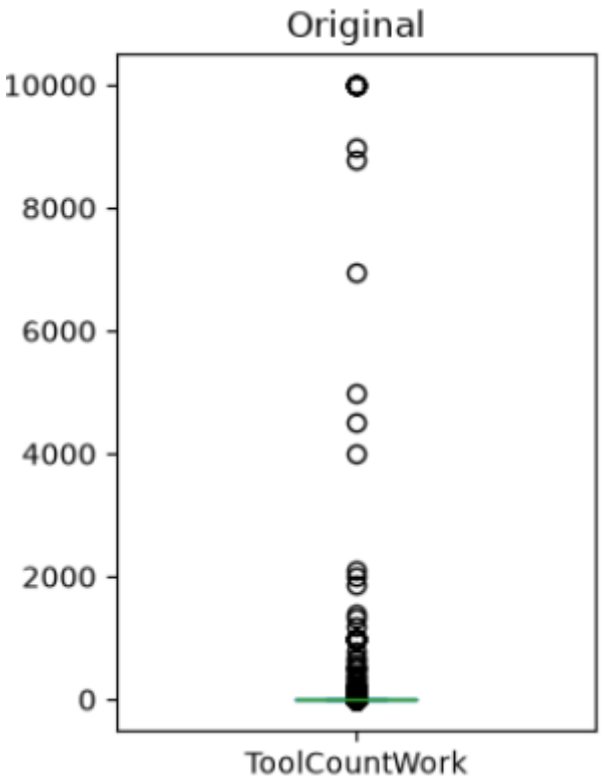

Distribucion de nulos para YearsCode
nulos: 6149
validos: 43042
12.50%
87.50%


50
40
30
20
10
0
YearsCode

- **ToolCountWork**

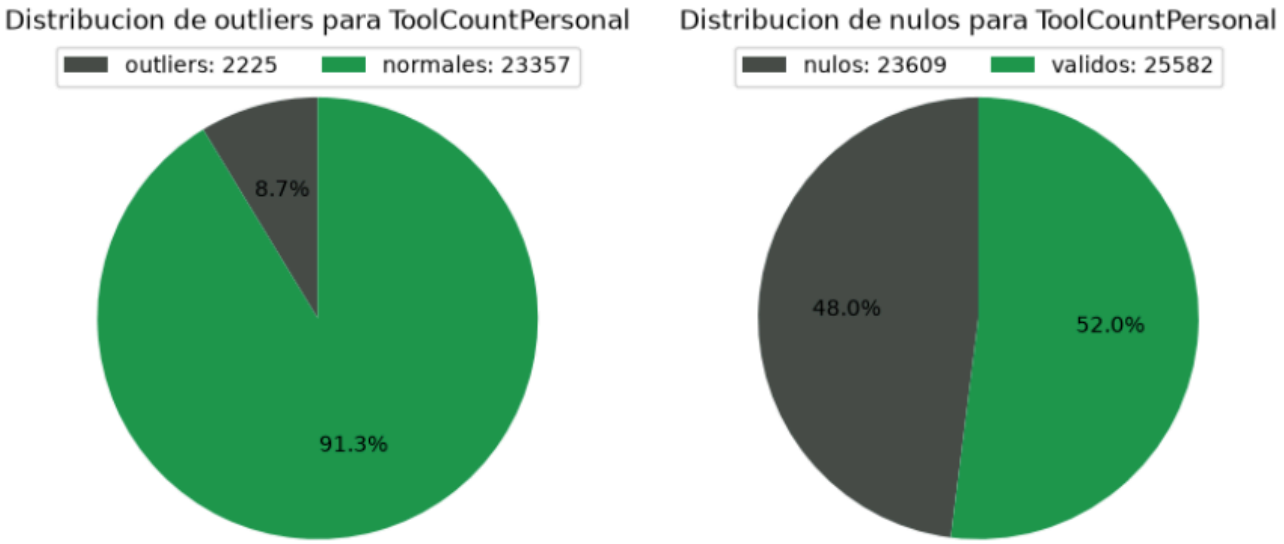


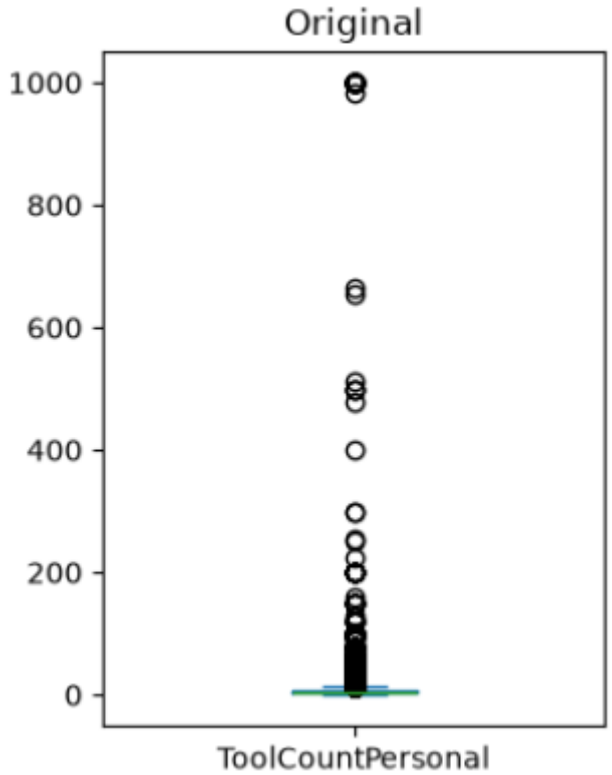




Aquí se observa claramente la presencia de outliers causando un sesgo a la derecha. Esto será tratado posteriormente en la limpieza de datos.

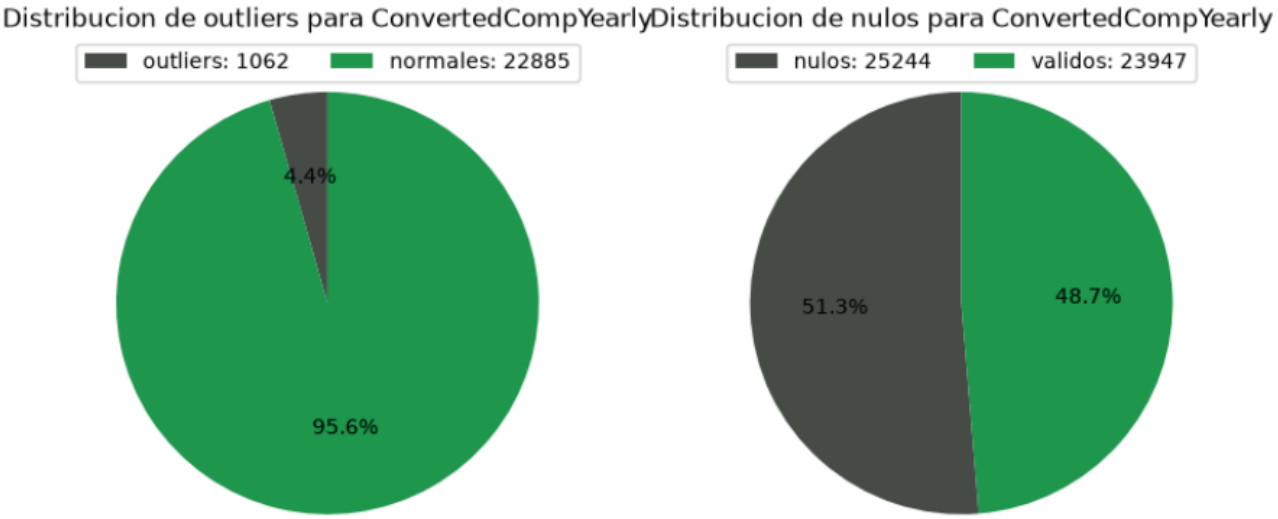
- **ToolCountPersonal**

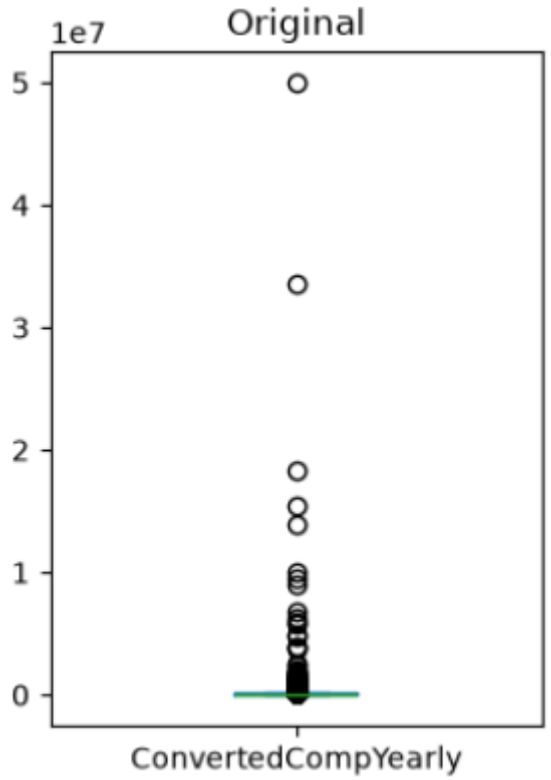




Aquí también se observa claramente la presencia de outliers causando un sesgo a la derecha. Al igual que la variable anterior, será tratada posteriormente en la limpieza de datos.

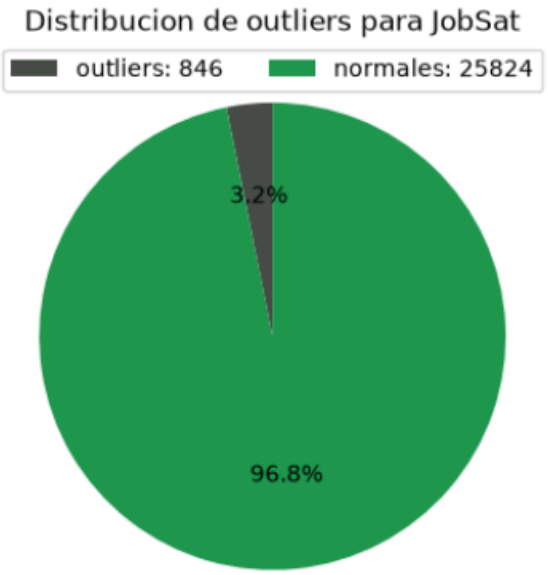
- **ConvertedCompYearly**

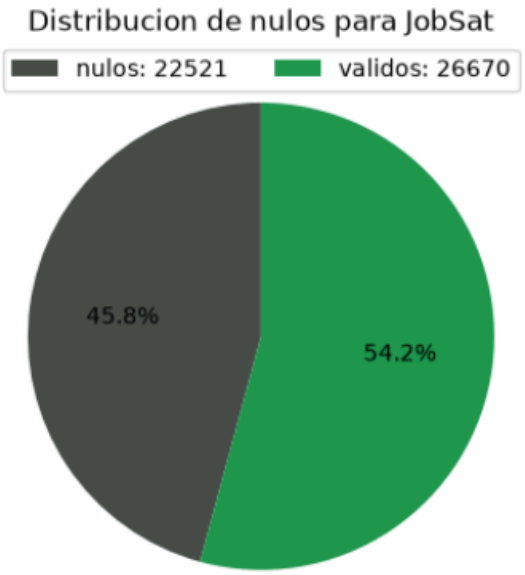


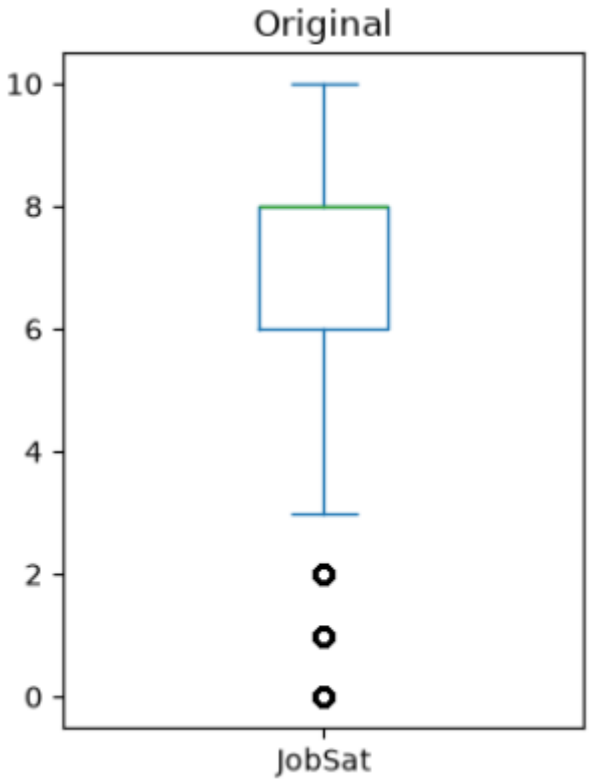


Para esta variable observamos un sesgo a la derecha.

- **JobSat**







Para esta variable observamos que la distribución hacia la izquierda, por lo tanto tiene un sesgo negativo.

5. Limpieza de la base de datos

Como primera estrategia de limpieza (y más básica) eliminamos aquellos registros de los datos que son duplicados entre sí y la variable ID de fila que no no es de utilidad.

- **Variables no incluidas en el análisis**

  Para poder realizar una explicación a detalle, reducir la dimensionalidad de los datos y enfocar el análisis de datos hacia un campo de interés mayor, a nuestro criterio, decidimos realizar la extracción de ciertas variables del Dataset. Toda la información y decisiones fueron tomadas a partir del esquema (*schema.csv*) de metadatos provisto por la cátedra y que es mostrado el procedimiento de recolección de las evidencias que proponemos en la Notebook entregada. A continuación las detallamos

  - **Variables de respuesta libre**

    Todas estas tenían por objetivo que el usuario pudiera plasmar, entre otras cosas, herramientas, factores, etc que no se encontraban entre las opciones. Así, decidimos extraerlas del conjunto de datos porque contienen una gran cantidad de valores nulos y la normalización y análisis de sus valores es muy costoso.



- TechEndorse_13_TEXT
- TechOppose_15_TEXT
- JobSatPoints_15_TEXT
- SO_Actions_15_TEXT
- LanguagesHaveEntry
- LanguagesWantEntry
- DatabaseHaveEntry
- DatabaseWantEntry
- PlatformHaveEntry
- PlatformWantEntry
- WebframeHaveEntry
- WebframeWantEntry
- WebframeWantEntry
- DevEnvHaveEntry
- DevEnvWantEntry
- SOTagsHaveEntry
- SOTagsWant Entry
- OfficeStackHaveEntry
- OfficeStackWantEntry
- CommPlatformHaveEntry
- CommPlatformWantEntry
- AIModelsHaveEntry
- AIModelsWantEntry
- AIAgentKnowWrite
- DevEnvHaveEntry
- DevEnvWantEntry
- SOTagsHaveEntry
- SOTagsWantEntry
- AIAgentOrchWrite
- AIAgentObsWrite
- AIAgentExtWrite
- AIExplain
- AIOpen

- **Variables asociadas al uso de StackOverflow**

  Todas estas tenían el objetivo de descubrir la comunidad de usuarios de StackOverflow y su uso de la plataforma, que no es de nuestro intereses en este momento. Las detectamos porque al inicio de su nombre contienen 'SO' haciendo referencia a StackOverflow.

  - SO_Actions_1
  - SO_Actions_16
  - SO_Actions_3
  - SO_Actions_4
  - SO_Actions_5
  - SO_Actions_6
  - SO_Actions_9
  - SO_Actions_7
  - SO_Dev_Content
  - SOComm
  - SOFriction
  - SO_Actions_10
  - SO_Actions_15
  - SO_Actions_15_TEXT
  - SOTags
  - SOTagsHaveEntry
  - SOTagsWant Entry
  - SOAccount
  - SOVisitFreq
  - SODuration
  - SOPartFreq

- **Variables asociadas a la compra de tecnología**

  Tenian el objetivo de representar el contexto e influencia de compras tecnológicas, por lo que no es de nuestro interés para este análisis de datos en específico.

  - **TechEndorseIntro**
  - **PurchaseInfluence**

Lo detallado hasta este punto es solo una limitación del dominio de datos que tomaremos en consideración, en etapas posteriores realizaremos análisis de limpieza de datos para trabajar con más precisión.

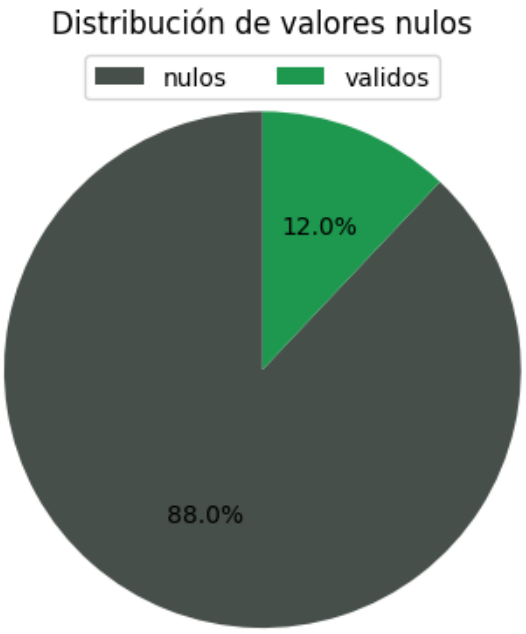
- **Variables no-numéricas con un porcentaje de valores nulos alto**

Realizamos un análisis para identificar la distribución de valores nulos en estas variables donde, por estándar aplicado dada nuestra decisión, decidimos eliminar todas aquellas que tienen más de un 80% de valores nulos en su conjunto.

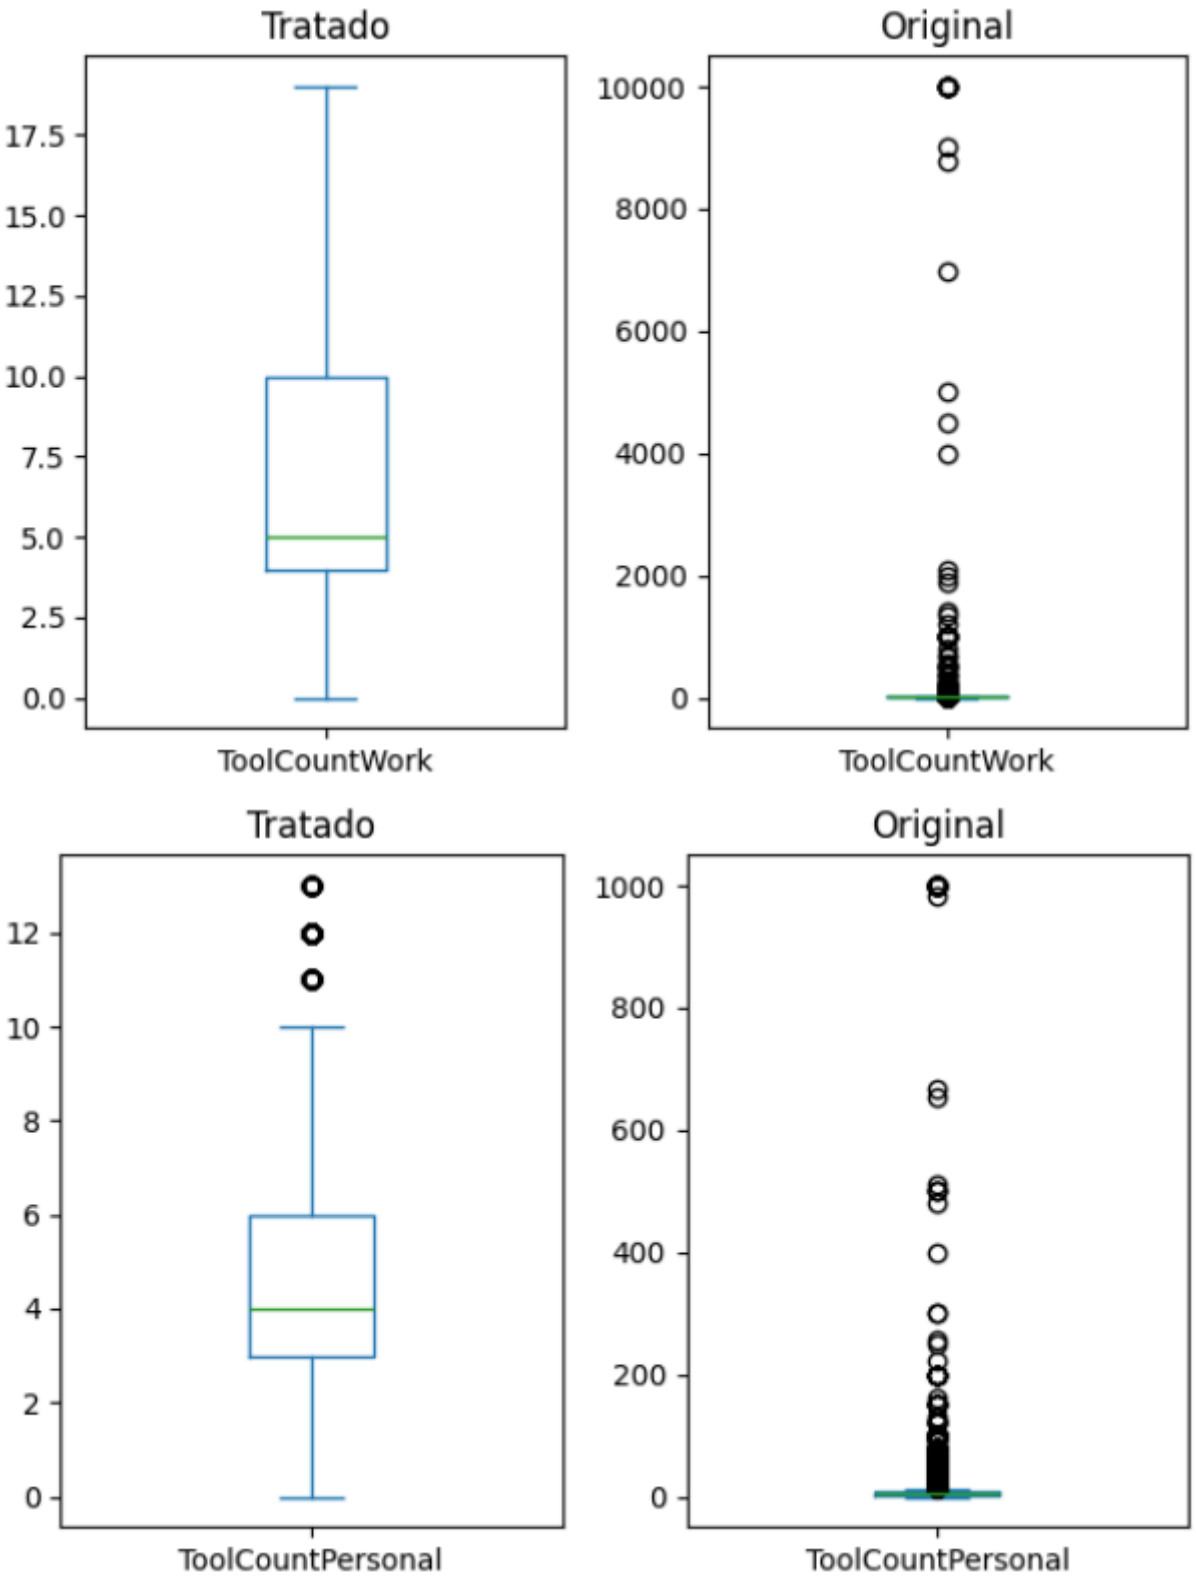
A continuación detallamos aquellas variables que serán removidas:

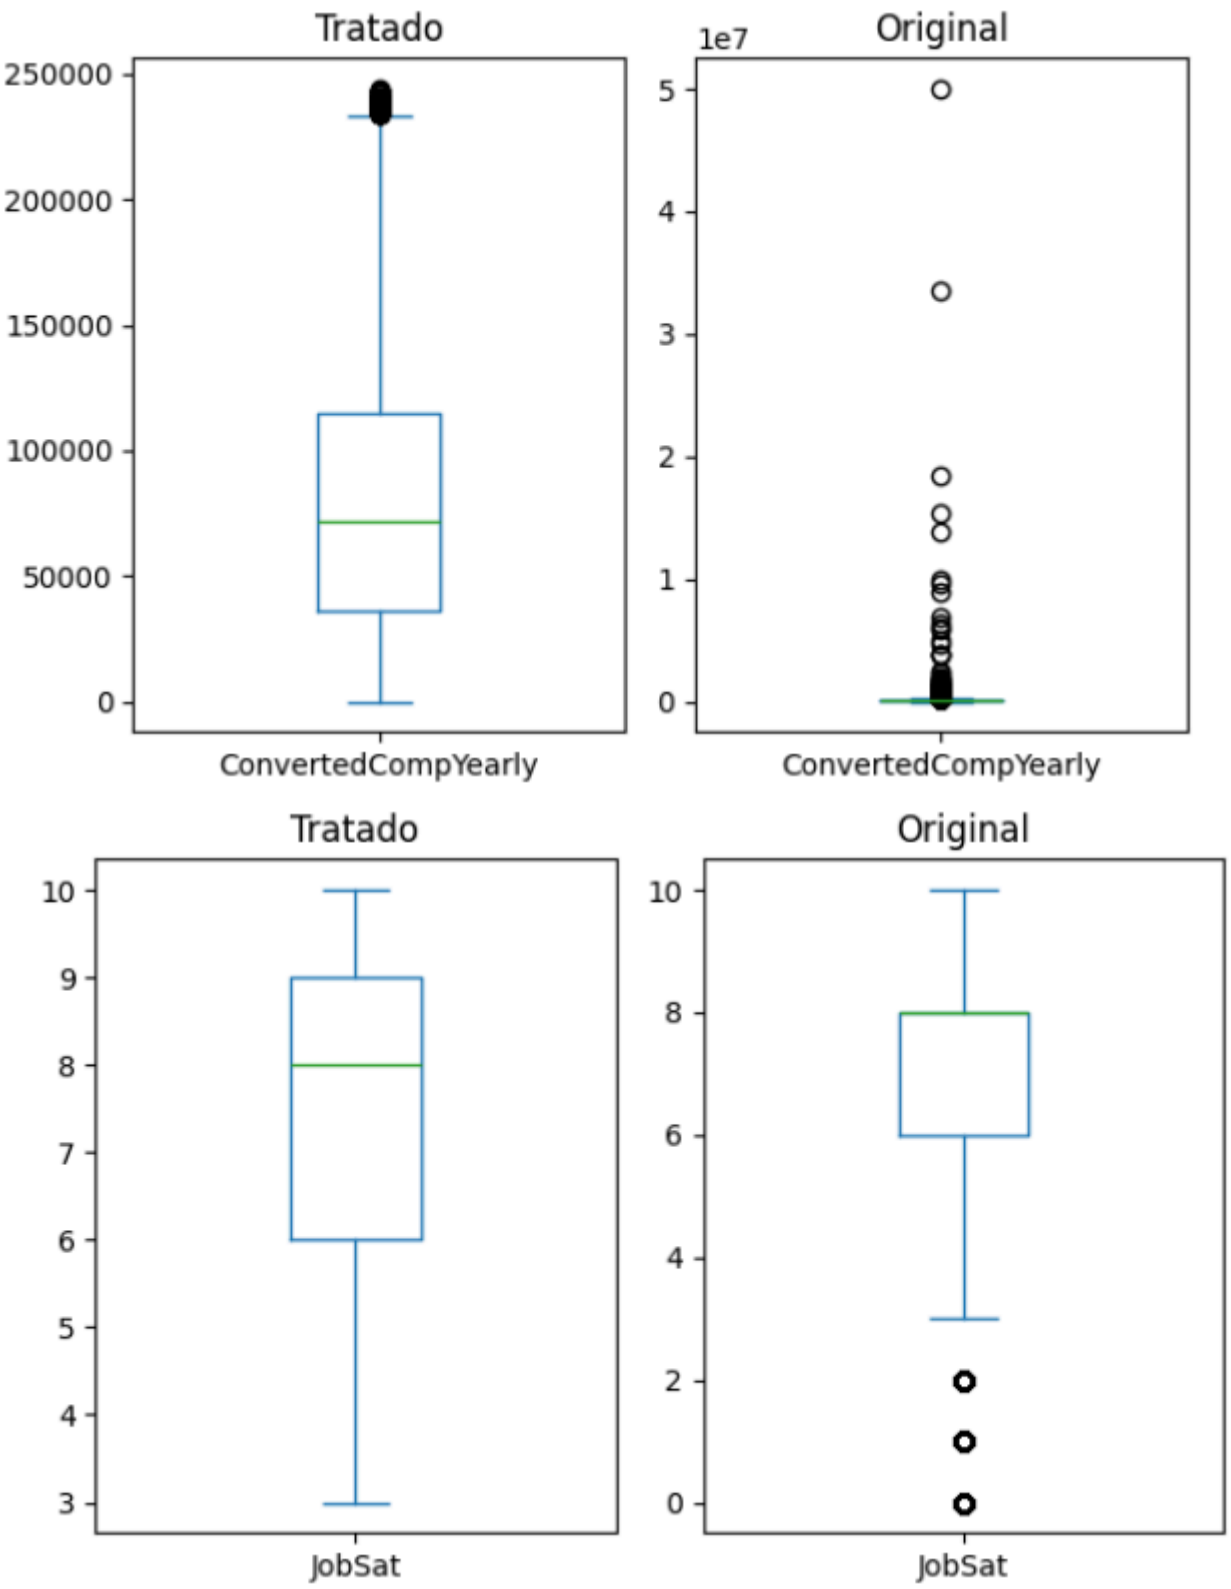
- **AIAgentObserveSecure**
- **AIAgentKnowledge**
- **AIAgentOrchestration**
- **AIAgentImpactStrongly disagree**
- **AIAgentImpactSomewhat disagree**
- **AgentUsesGeneral**
- **AIAgentImpactStrongly agree**
- **AIAgentExternal**
- **AIAgentChallengesStrongly disagree**
- **AIAgentImpactNeutral**

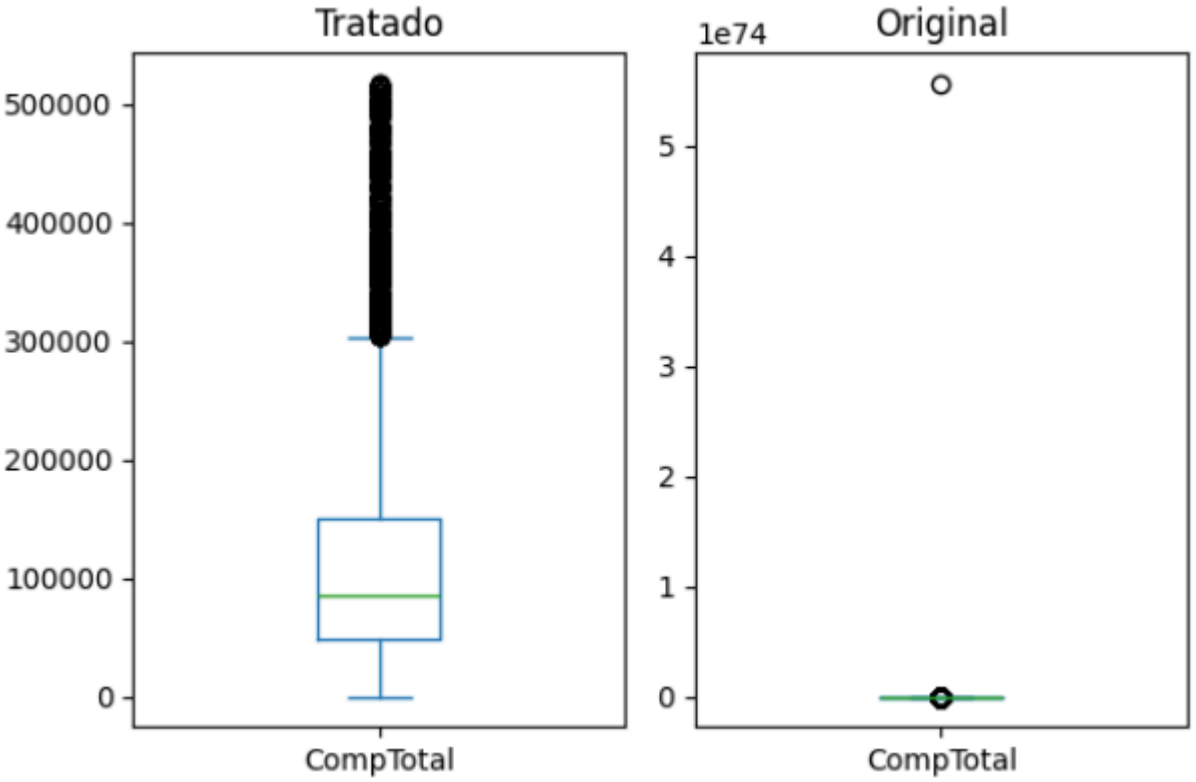
En conjunto, promedian un 88% de valores nulos, por lo que se justifica su eliminación.



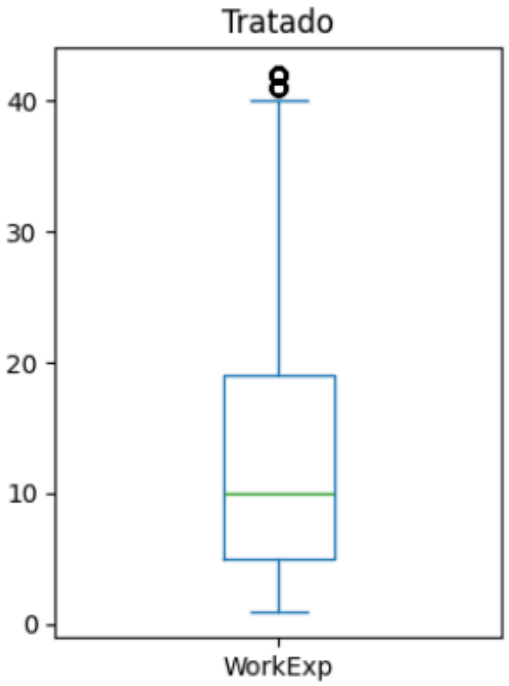
Como mencionamos se trataron variables como ToolCountWork, ToolCountPersonal, ConvertedCompYearly, JobSat, CompTotal, WorkExp y YearsCode. Mostramos los resultados y la limpieza de outliers obtenida.

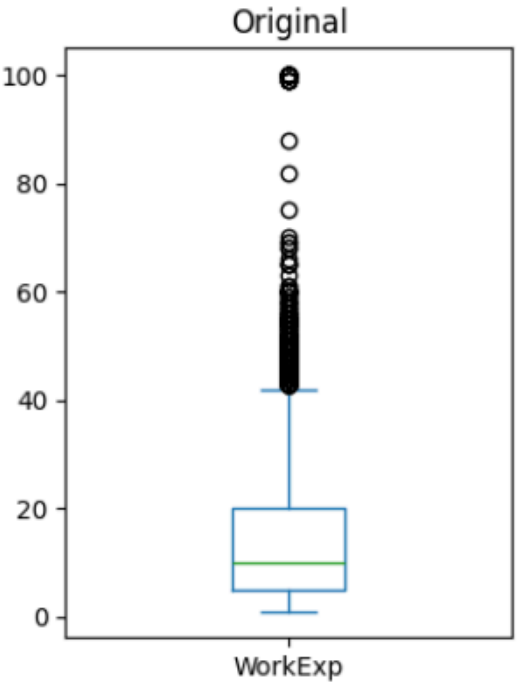


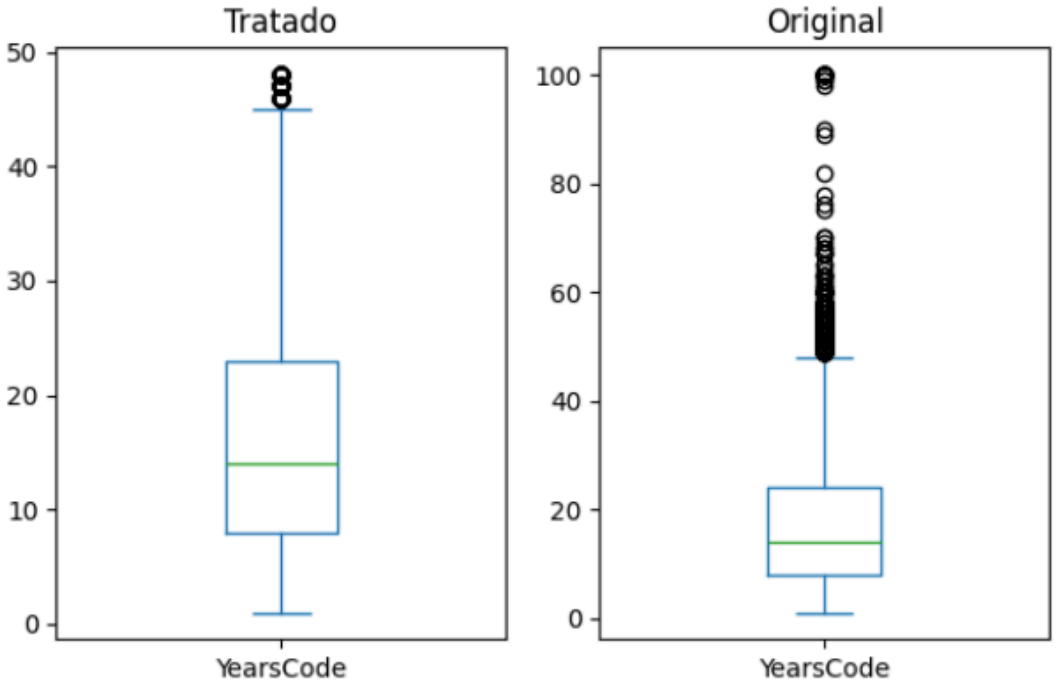

Tratado
250000
200000
150000
100000
50000
0
ConvertedCompYearly
Original
1e7
5
4
3
2
1
0
ConvertedCompYearly
Tratado
10
9
8
7
6
5
4
3
JobSat
Original
10
8
6
4
2
0
JobSat


Tratado
500000
400000
300000
200000
100000
0
CompTotal

Original
1e74
5
4
3
2
1
0
CompTotal


Tratado
40
30
20
10
0
WorkExp


Original
100
80
60
40
20
0
WorkExp


Tratado
50
40
30
20
10
0
YearsCode
Original
100
80
60
40
20
0
YearsCode

6 Transformación y codificación de variables

Para adecuar el conjunto de datos tanto a la representación gráfica del análisis exploratorio como a los modelos matemáticos posteriores, se aplicaron distintas transformaciones sobre las variables originales del dataset.

6.1 Renombrado de categorías y agrupación visual

Muchas de las variables cualitativas de la encuesta presentan cadenas de texto extensas como valores posibles (por ejemplo, *"Independent contractor, freelancer, or self-employed"* en la variable Employment). Para evitar la saturación visual y el solapamiento de etiquetas en los gráficos de barras de la Sección 3, se aplicó una función de mapeo que reemplaza los nombres originales por abreviaturas o códigos numéricos:

- **MainBranch:** Se codificaron las 6 modalidades principales de relación con la programación utilizando valores del 1 al 6.

- **EdLevel:** Se abreviaron los niveles educativos en Bd (*Bachelor's degree*), Md (*Master's degree*), CU (*College/University sin título*), Ss (*Secondary school*), Pd (*Professional degree*), Ad (*Associate degree*) y Ps (*Primary school*).

- **DevType:** Se redujeron los roles principales a Fs (*Full-stack*), Be (*Back-end*), Stud (*Student*), Arch (*Architect*), Fe (*Front-end*) y d_e (*Data engineer / DevOps*).

- **RemoteWork y NewRole:** Se sintetizaron las modalidades de trabajo en Remote, Person, H_p, H_r y Choice, y la búsqueda de nuevo rol en No, con_1, con_2, Yes_v y Yes_i.

- **OrgSize:** Se abreviaron los rangos de cantidad de empleados en 20-99, 100-499, <20, >10k, 1k-5k, 500-1k, Me (trabajador individual), 5k-10k y DK (*I don't know*).

- **Variables demográficas truncadas por cantidad de caracteres:** En los atributos cuyas opciones comenzaban con una palabra o código identificador, se recortó automáticamente el texto inicial: Employment a 6 caracteres (Employ, Indepe, Studen, Not em), Country a 3 letras (Uni, Ger, Ind, Fra, Can), Currency a su código ISO de 3 letras (EUR, USD, INR, GBP, CAD), Industry a 3 caracteres (Sof, Oth, Int, Fin), ICorPM a 5 letras (Indiv y Peopl) y Age hasta el primer espacio en blanco para conservar sólo el rango numérico (25-34, 35-44, etc.).

- **Experiencia y aprendizaje (LearnCodeChoose y LearnCodeAI):** Se recodificó el aprendizaje de nuevas habilidades en yes - master, no - master y yes - junr, y la formación en herramientas de IA según su propósito en IA_Prof (profesional), IA_Pers (personal), NoIA_Pers, No_learn y NoIA_Prof.

- **Stack tecnológico y herramientas:** Se emplearon acrónimos estándar para lenguajes, plataformas y entornos (tales como HT/CS para HTML/CSS, Py para Python, Sh para Bash/Shell, Ts para TypeScript, K8s para Kubernetes, VSC para VS Code, GH para GitHub y SO para Stack Overflow). Para AIModels se emplearon las siglas: GPT, CS (Claude Sonnet), GF (Gemini Flash), OAI-R y OAI-I (modelos de OpenAI), GP (GitHub Copilot) y Deep R (DeepSeek R1), además de Intj (IntelliJ), Curs (Cursor), GL (GitLab), MD (Markdown), Confl (Confluence) y SE (Stack Exchange).

Asimismo, se definió un umbral mínimo de frecuencia según la variable analizada (entre 1.000 y 2.400 registros), agrupando todas las categorías de menor aparición bajo la etiqueta **Otros**.

6.2 Desagregación de preguntas de selección múltiple

En las variables de múltiple respuesta (como tecnologías usadas o deseadas, bases de datos y plataformas), el dataset almacena todas las elecciones de un mismo usuario en una única celda separadas por punto y coma (;). Para obtener la distribución real de frecuencias, se transformaron estas columnas dividiendo las cadenas de texto por dicho delimitador y expandiendo cada elemento como un registro independiente antes de realizar el conteo.

6.3 Codificación numérica para análisis estadístico y multivariado

Dado que las técnicas de reducción de dimensionalidad y las pruebas de hipótesis requieren operar sobre escalas numéricas, se transformaron las variables cualitativas ordinales y dicotómicas seleccionadas:

- **Tratamiento de respuestas no escalables:** Las opciones que no representan una posición dentro de una escala ordinal (Prefer not to say, Other (please specify) e I don't know) fueron recodificadas como valores nulos (NaN).

- **Escalas ordinales:** Se asignaron valores enteros crecientes respetando la jerarquía natural de cada atributo en Age (de 0 para *18-24 años* a 5 para *65 años o más*), EdLevel (de 0 a 6), OrgSize (de 0 a 7) y AIAcc (de *Highly distrust* a *Highly trust*).

- **Variables dicotómicas y binarización:** Las columnas de tipo ...Choice fueron mapeadas a 1 (*Yes*) y 0 (*No*). De manera análoga, para el contraste de hipótesis bivariado, la variable AIAcc se binarizó agrupando los niveles de desconfianza en 0, los de confianza en 1 y asignando NaN a la postura neutral (*Neither trust nor distrust*).

6.4 Tratamiento de valores atípicos (outliers)

Como vimos en la sección 4 mediante los boxplots originales, varias de las variables numéricas presentaban valores extremos tan altos que aplastan la caja del gráfico y no nos dejaban ver cómo se distribuían realmente los datos.

Para solucionar esto y quedarnos con la distribución representativa de la muestra, aplicamos un filtrado estadístico basado en el criterio del **rango intercuartílico (IQR)** para detectar y eliminar los valores atípicos en las seis variables analizadas, obteniendo los siguientes resultados al comparar los gráficos originales con los tratados:

- **ToolCountWork y ToolCountPersonal:** En los gráficos originales teníamos respuestas extremas de hasta 10.000 y 1.000 herramientas que generaban un fuerte sesgo a la derecha. Al eliminar el 8,6% (2.384 registros) y el 8,7% (2.225 registros) de outliers respectivamente, logramos recuperar la caja central de los datos, viendo que lo habitual es utilizar entre 4 y 10 herramientas en el trabajo (con bigote en 19) y entre 3 y 6 en proyectos personales (con bigote superior en 10).

- **ConvertedCompYearly:** En ambas variables salariales los valores atípicos distorsionan por completo la escala (llegando a 5×10^7 en dólares y hasta 1×10^{74} en moneda local por la diferencia de cambio entre divisas). Luego del filtrado (4,4% de outliers en ConvertedCompYearly), pudimos visualizar la distribución real de los ingresos, que en el caso del salario anual en dólares concentra su caja central entre los 36.000 y 115.000 dólares aproximadamente, con bigote superior cerca de los 233.000.

- **WorkExp y YearsCode:** Originalmente ambas variables tienen registros que llegaban hasta los 100 años. Eliminando alrededor del 1% de datos atípicos (413 registros en cada una), acotamos la experiencia laboral a un máximo de 40-42 años (con mediana en 10 años y la caja entre 5 y 19) y los años totales programando a un máximo de 45-48 años (con mediana en 14 años y la caja entre 8 y 23).

- **JobSat:** A diferencia de las anteriores, esta variable presenta un sesgo hacia la izquierda (negativo), ya que la mayoría de los desarrolladores puntúa su satisfacción entre 6 y 8. Por este motivo, el criterio de IQR detectó como outliers inferiores a las puntuaciones muy bajas (0, 1 y 2, que representan el 3,2% con 846 casos). Al filtrarlos en el gráfico tratado, la distribución quedó acotada entre 3 y 10, desplazando el rango de la caja entre 6 y 9.

7. Reducción de dimensionalidad

Una vez limpia la base, aplicamos técnicas de reducción de dimensionalidad.
El objetivo era ver cómo se relacionan entre sí las variables cuantitativas y algunas cualitativas ordinales de interés, y usar esas relaciones como punto de partida para las hipótesis.

Todo el análisis está en la sección “Reducción de dimensionalidad" del notebook, dentro del bloque Limpieza de datos.

7.1 Preparación de los datos

Las técnicas usadas trabajan con distancias en un espacio numérico, así que primero convertimos las variables cualitativas ordinales a una escala numérica que respete su orden natural. En el notebook, los mapeos están en las celdas que siguen al título "Mapeamos las variables cualitativas ordinales":

- **AIAcc** (confianza en la precisión de la IA): de Highly distrust a Highly trust.
- **Age**: rangos etarios de 0 (18-24 años) a 5 (65 años o más).
- **EdLevel**: de 0 (educación primaria) a 6 (doctorado o título profesional).
- **OrgSize**: de 0 (freelancer) a 7 (10.000 empleados o más).
- **…Choice** (DatabaseChoice, LanguageChoice, PlatformChoice, WebframeChoice, DevEnvsChoice, AIModelsChoice): variables dicotómicas, codificadas como 1 (Yes) y 0 (No).

Las respuestas que no expresan una posición en la escala las tomamos como valores nulos: Prefer not to say, Other (please specify) e I don't know.
Después eliminamos los registros con nulos en las variables elegidas, porque las técnicas aplicadas **no admiten valores faltantes**.

Además, las variables tienen escalas muy distintas: la remuneración anual en dólares llega a cientos de miles, mientras que las ordinales toman valores de 0 a 7.
Sin estandarizar, la remuneración dominaría por completo la varianza. Por eso estandarizamos todas con StandardScaler (media 0, desvío 1).

La variable objetivo de cada análisis no participa de la proyección: se excluye y se usa solo para colorear los puntos. Así se puede ver si la estructura que encuentran las demás variables se corresponde con ella.

7.2 Técnicas utilizadas

Aplicamos y comparamos tres técnicas vistas en clase:

- **PCA**: Es lineal y busca las direcciones de máxima varianza. Elegimos PCA como técnica principal porque es la única de las tres que se puede interpretar, mediante las cargas (loadings) de cada variable original en cada componente y el biplot.

- **t-SNE**: no es lineal y preserva las vecindades locales.
  Sirve para ver agrupamientos, pero las distancias globales y los ejes no tienen interpretación directa.

- **UMAP**: Tampoco es lineal. Preserva la estructura local y en parte la global.
  Para que los resultados se puedan reproducir, fijamos random_state=10 y n_jobs=1 ya que el paralelismo no garantiza resultados idénticos entre ejecuciones.

Las tres se proyectaron a 2 componentes para poder graficarlas.

7.3 Análisis 1: Estructura respecto de los años de experiencia laboral

En la primera corrida usamos YearsCode, ConvertedCompYearly, JobSat, Age, EdLevel, OrgSize, ToolCountWork y AIAcc, y coloreamos los puntos por la variable objetivo WorkExp.

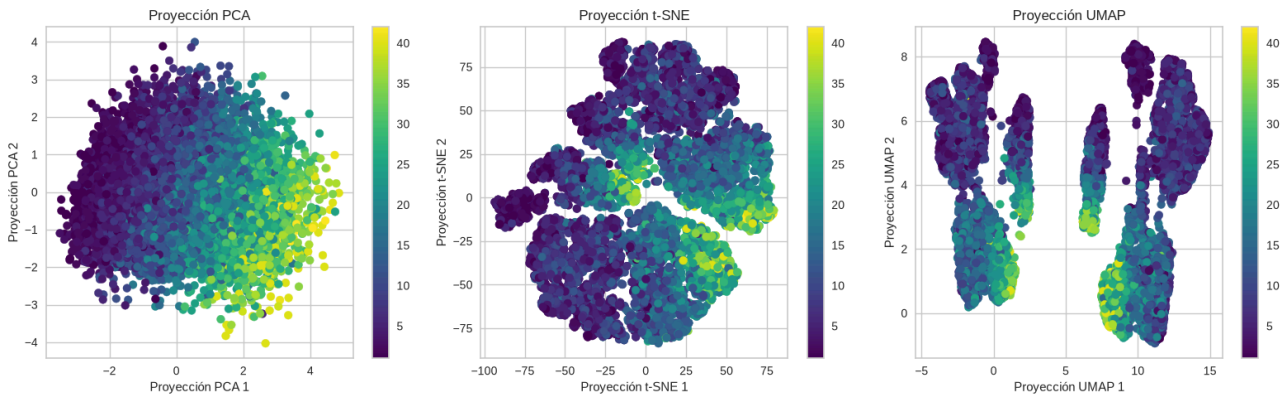


Fig. 7.1: *Proyecciones en dos dimensiones con PCA, t-SNE y UMAP.*
Cada punto es un encuestado, coloreado según sus años de experiencia laboral (WorkExp): violeta, poca experiencia; amarillo, mucha.

En la proyección PCA se ve un gradiente claro a lo largo de la primera componente: los encuestados con más experiencia quedan hacia la derecha (valores altos de PC1).

t-SNE y UMAP separan los datos en varios grupos, probablemente por el carácter discreto de las variables ordinales (edad, tamaño de organización, nivel educativo).

Dentro de cada grupo, los valores altos de experiencia aparecen concentrados en regiones puntuales. Esto confirma que la experiencia está asociada a la estructura de los datos, aunque estas técnicas no permiten explicar con qué variables.

Las dos primeras componentes del PCA explican el 26.9% y el 14.2% de la varianza, 41.1% en total. No es un porcentaje alto, por lo que las conclusiones que siguen son orientativas. Para interpretar las componentes usamos el biplot (Fig. 7.2).

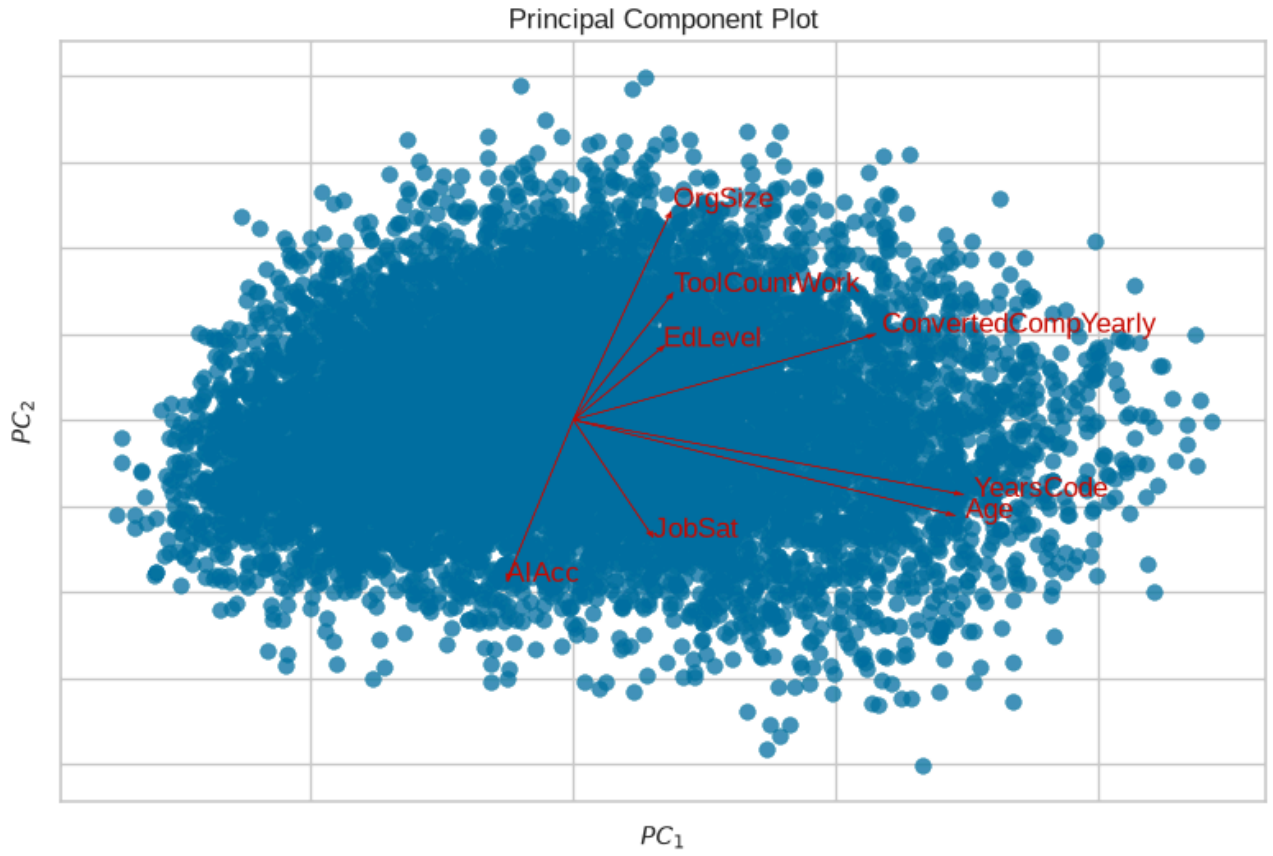


Fig. 7.2: *Biplot de las dos primeras componentes principales. Las flechas rojas son las variables originales; el ángulo entre flechas indica cuánto se correlacionan*.

PC1 representa la **trayectoria o seniority del desarrollador**.
Las variables que más aportan son YearsCode, Age y ConvertedCompYearly, y todas pesan en el mismo sentido.
Es la misma dirección del gradiente de WorkExp en la Fig. 7.1: los desarrolladores con más años programando, más edad y más ingresos son también los de más experiencia laboral.

YearsCode y Age son prácticamente colineales en el biplot. Esto concuerda con la fuerte correlación que vimos en el análisis exploratorio entre los años de programación y la experiencia laboral.

PC2 representa el **contexto organizacional**.

Pesan sobre todo OrgSize y ToolCountWork, de un lado, y AIAcc y JobSat, del otro.
PC1 posee AIAcc con carga es baja y negativa (−0,10), por lo que su peso real está en PC2 (−0,45).

En el biplot, su vector forma un ángulo obtuso (> 90° & < 180°) con el de la remuneración anual. Eso sugiere una posible asociación negativa entre ambas, aunque el plano representa solo el 41% de la varianza.

Estas observaciones motivaron dos de las hipótesis de la sección 8:

- **Hipótesis bivariada**:
  Si existen diferencias de remuneración entre quienes confían y quienes no confían en la IA.

- **Hipótesis multivariada**:
  Una posible relación lineal entre los años de experiencia laboral y el resto de las variables.

Varianza explicada por componente

Para saber cuántas componentes harían falta para representar los datos de forma adecuada, ajustamos un PCA con todas las componentes y graficamos la varianza individual y la acumulada (Fig. 7.3).

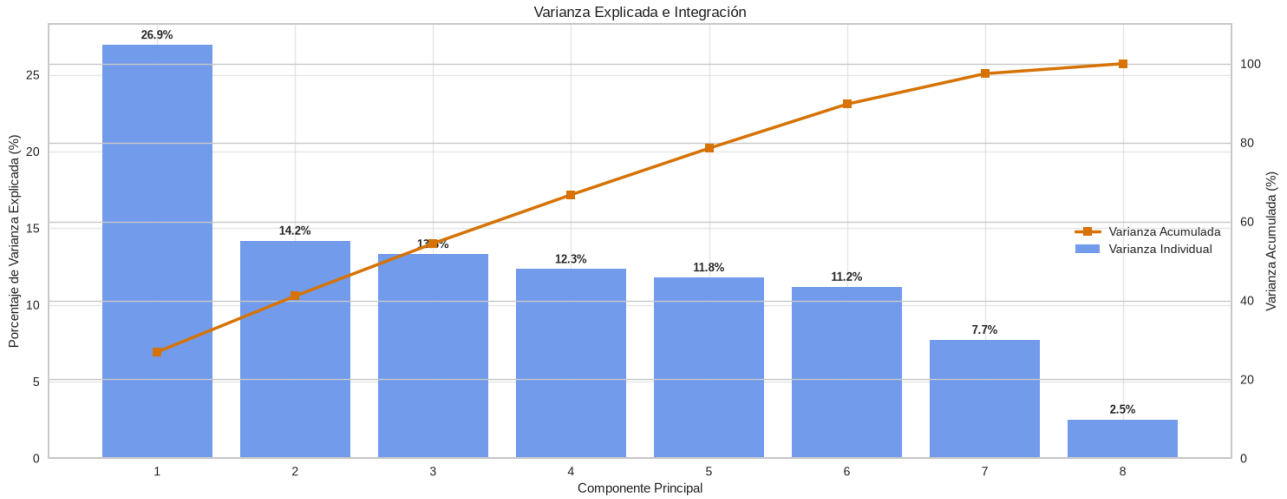


Fig. 7.3: *Porcentaje de varianza explicada por cada componente principal (barras) y varianza acumulada (línea naranja), para el primer análisis*.

A partir de la segunda componente, cada una aporta una porción parecida de la varianza: Entre el 11% y el 14% hasta la sexta.

Eso indica que la información no se concentra en pocas direcciones. Hacen falta 5 componentes para superar el 75% y 6 para acercarse al 90%, es decir, casi tantas como variables originales (8).

Por lo tanto, el conjunto no admite una reducción fuerte de dimensionalidad sin una pérdida importante de información. Las variables aportan información en buena medida independiente entre sí, salvo el bloque experiencia–edad–años de código, que es redundante.

7.4. Análisis 2: Estructura respecto de la remuneración anual

En la segunda corrida tomamos como objetivo la remuneración anual en dólares (ConvertedCompYearly). Agregamos WorkExp a las variables proyectadas y también las variables dicotómicas …Choice, que indican si el encuestado usa tecnologías de bases de datos, lenguajes, plataformas, frameworks web, entornos de desarrollo y modelos de IA.

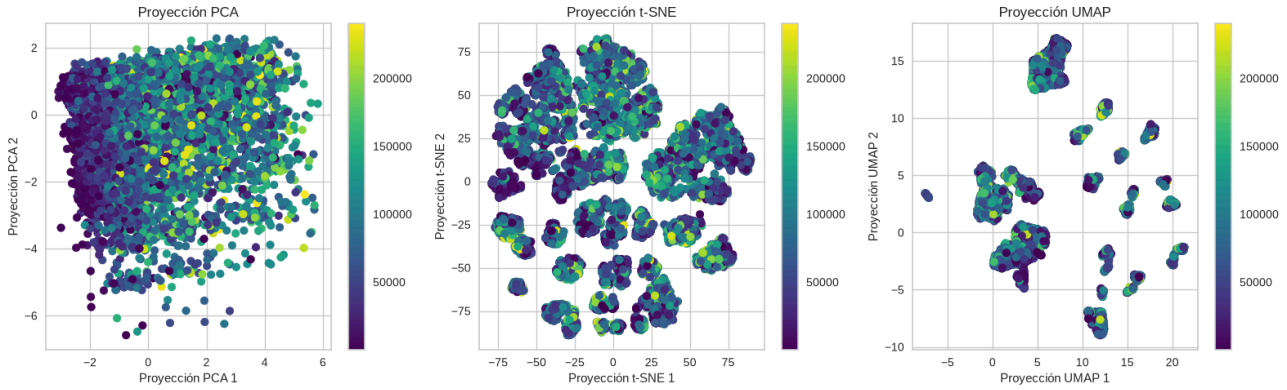


Fig. 7.4: *Proyecciones en dos dimensiones con PCA, t-SNE y UMAP, coloreadas por la remuneración anual en dólares (ConvertedCompYearly).*

En PCA, las remuneraciones bajas se concentran en el extremo izquierdo de PC1 y las altas aparecen a medida que PC1 crece, aunque mucho más mezcladas que en el caso de la experiencia.
Las dos primeras componentes explican el 21.3% y el 14.2% de la varianza (35.5% total).

t-SNE y UMAP generan muchos grupos pequeños y bien separados, pero dentro de cada uno la remuneración está mezclada.
Esto se explica por las seis variables dicotómicas: al tomar solo los valores 0 o 1, sus combinaciones forman grupos discretos de encuestados, y esa estructura es la que capturan las técnicas no lineales.

Por eso, como no tiene relación con el salario, t-SNE y UMAP no aportan información útil sobre la remuneración y nos quedamos con PCA para interpretar.

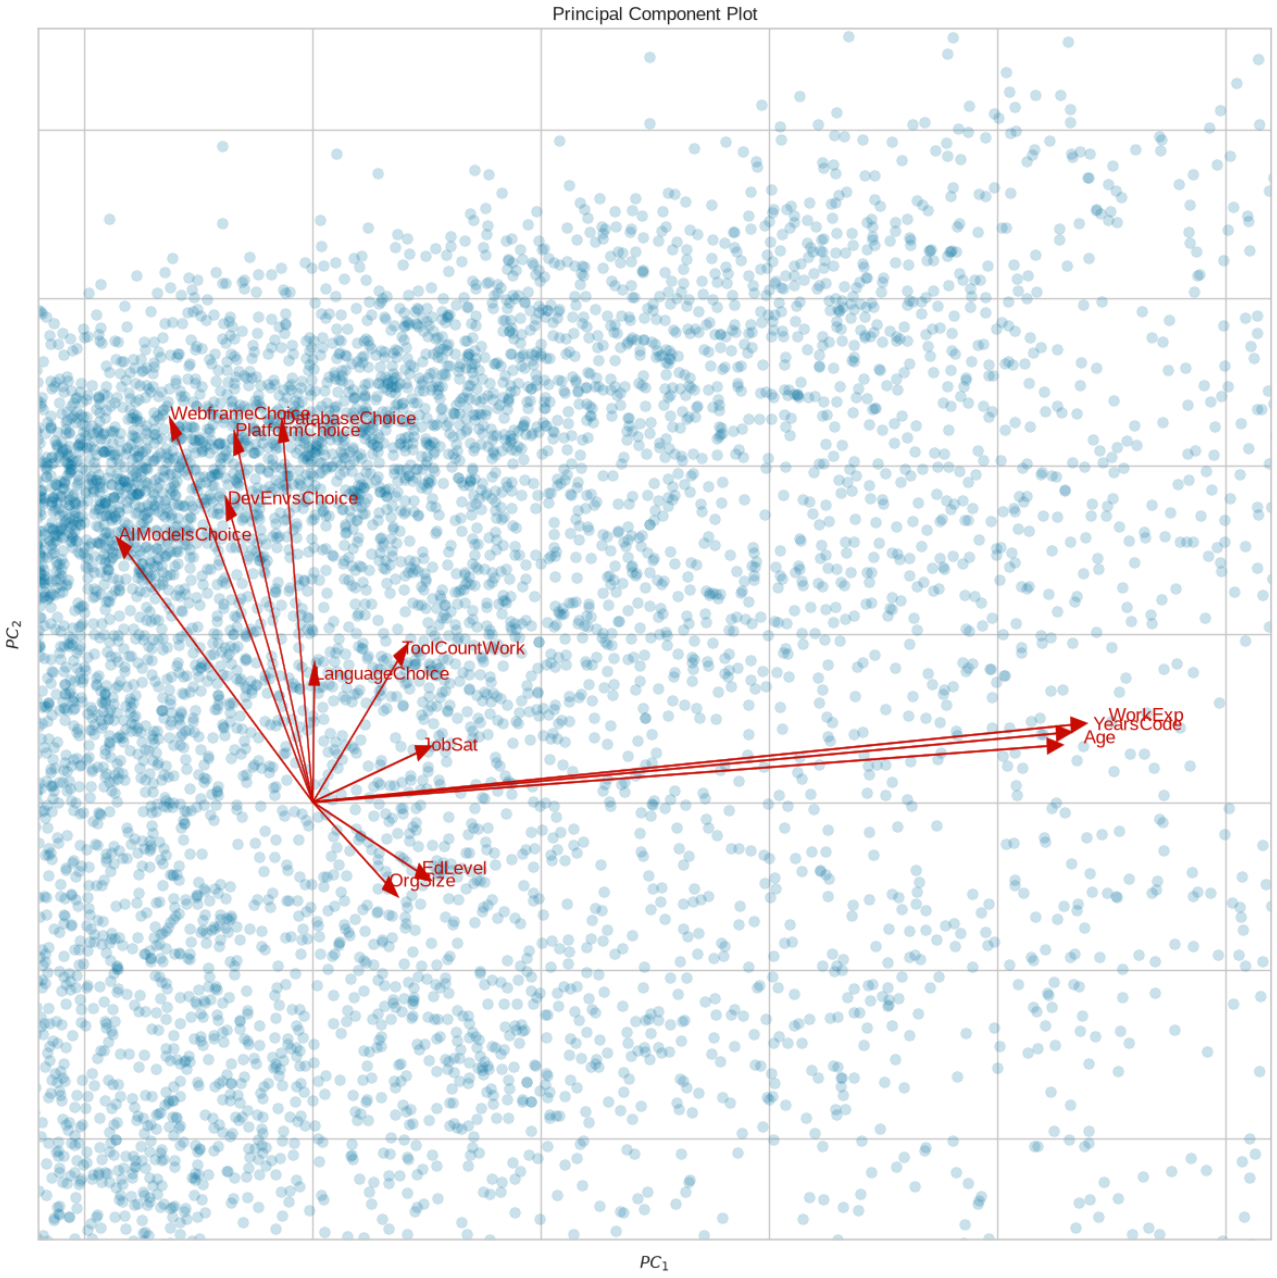


Fig. 7.5: *Biplot ampliado de las dos primeras componentes del segundo análisis. Las variables de experiencia se alinean con PC1 y las variables dicotómicas de uso de tecnologías con PC2.*

PC1 representa la **experiencia**.
Lo forman WorkExp, YearsCode y Age, con cargas casi idénticas (≈0,55–0,57) y vectores casi superpuestos en el biplot.
Confirma lo visto en el primer análisis: *las tres variables miden prácticamente lo mismo*.

PC2 representa el **uso de tecnologías**.
Lo forman las variables …Choice, que casi no tienen peso en PC1. Son prácticamente ortogonales a la experiencia: *usar o no ciertas tecnologías no se relaciona con los años de trayectoria*.

Como las remuneraciones más altas aparecen hacia valores altos de PC1 (Fig. 7.4), se puede pensar que la experiencia, la edad y los años de programación se asocian con un mayor salario.

Pero la reducción de dimensionalidad no alcanza para afirmarlo: es una relación que hay que comprobar estadísticamente, y la abordamos en la hipótesis multivariada (sección 8) mediante una regresión lineal.

7.5. Conclusiones

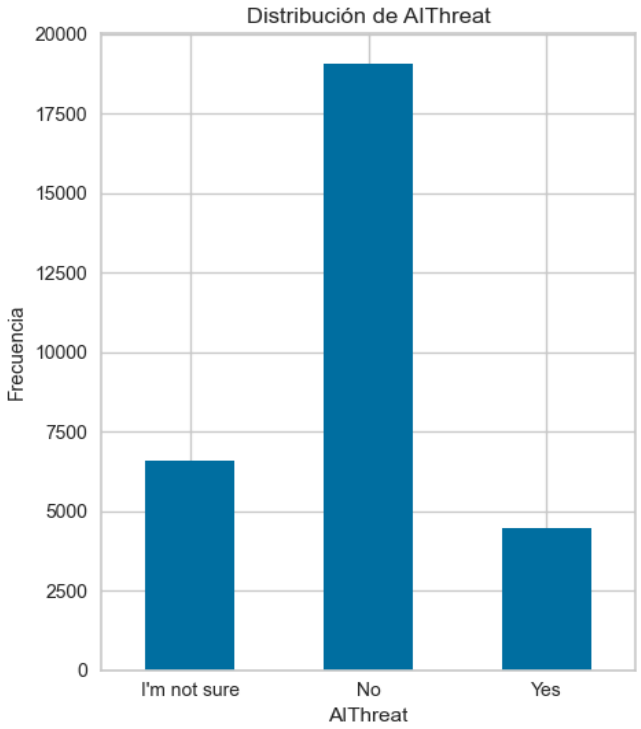
- La primera componente principal se interpreta como un eje de seniority: años de experiencia, años de programación, edad y, en menor medida, remuneración
- WorkExp, YearsCode y Age son altamente redundantes entre sí.
- La varianza se reparte entre muchas componentes, así que dos dimensiones no alcanzan para representar el conjunto (entre 35% y 41% de varianza explicada).
- t-SNE y UMAP se ven dominados por las variables discretas, por lo que el análisis se apoya sobre todo en las cargas y el biplot de PCA.
- Las relaciones observadas motivaron las hipótesis bivariada (confianza en la IA y remuneración) y multivariada (experiencia y salario), que se validan en la sección 8.

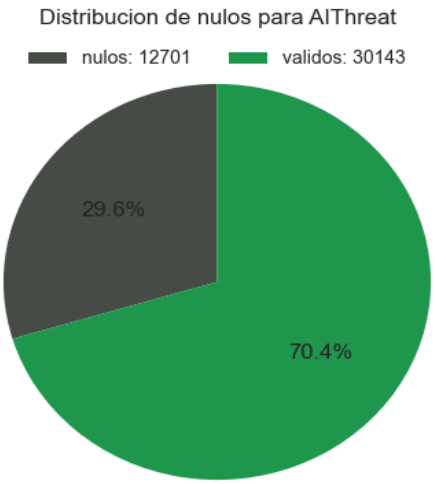
8. Planteo y validación de hipótesis

- **Univariada**: De aquellos desarrolladores que no tienen miedo a que la ia reemplace su trabajo, su experiencia laboral es superior a 5 años (seniors).

  Mediante el Biplot observado en el análisis de reducción de dimensionalidad pudimos observar como la confianza en la IA tenia una correlación negativa con la componente principal 1 que explicaba en si el crecimiento de los años de experiencia, por lo que queremos verificar que de aquellos que no confían de la IA su experiencia laboral sea superior a 5 años.

  Para lograrlo, teniendo la variable **AIThreat** con distribución:





  Filtramos aquellos encuestados que justamente si tienen miedo que la inteligencia artificial reemplace su trabajo con valor **No**. Además, eliminamos los valores nulos para quedarnos justamente como se ve en el gráfico con 30.143 registros.

  Para realizar la comprobación estadística, utilizaremos un test t de Student para una muestra y de una cola. Planteamos como hipótesis nula que la media de años de experiencia laboral de los desarrolladores es menor o igual a 5 años, mientras que la hipótesis alternativa establece que dicha media es superior a 5 años.

  - H0: u <= 5
  - H1: u > 5

Por el teorema del límite central, podemos no comprobar la normalidad de la muestra gracias a que la media de la misma muestra tiende a una distribución normal con un n > 30, en este caso con 30.143 registros.

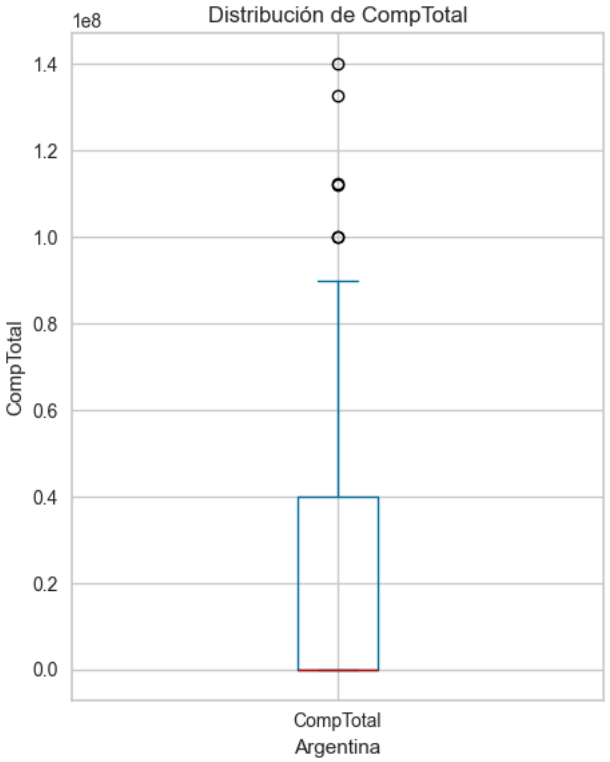
Así, usamos sklearn.stats para usar su algoritmo de t student a una cola planteando los valores dichos anteriormente, valor de referencia de 5 (anios) y método 'greater' en la opción de alternativa.

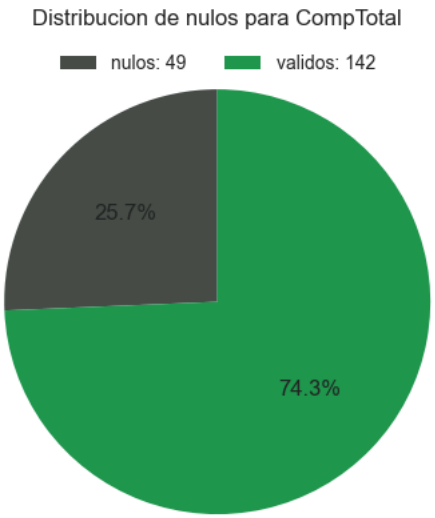
Finalmente, obtuvimos como resultado:
- Estadístico t: 106.194
- p-valor: 0.000

Por lo que dado el p-valor < 0.05, rechazamos la hipótesis nula y aceptamos que la media de los años de experiencia laboral es significativamente superior a 5 años para aquellos encuestados que no tienen miedo a que la inteligencia artificial reemplace su trabajo

- **Univariada planteada por cátedra:** Los desarrolladores que respondieron la encuesta de Argentina tienen un salario 3 veces mayor al Salario Mínimo, Vital y Móvil (SMVM).

  En esta hipótesis tenemos dos variables de interés con las que trabajaremos donde una es **CompTotal**, que contiene el sueldo anual del encuestado en su moneda local, y **Country** que contiene el país de residencia del encuestado. Además, vemos que la distribución de **CompTotal**:





Así, nos quedamos con aquellos datos en los que el país de residencia sea justamente Argentina para analizar el comportamiento de **CompTotal** mediante 142 registros.

Para realizar la comprobación estadística, utilizaremos un test t de Student para una muestra y de una cola. Planteamos como hipótesis nula que la media del sueldo anual de los desarrolladores es superior o igual a tres veces el Salario Mínimo, Vital y Móvil (SMVM), mientras que la hipótesis alternativa establece que dicha media es inferior a ese valor.

- H0: u <= 3 * SMVM
- H1: u > 3 * SMVM

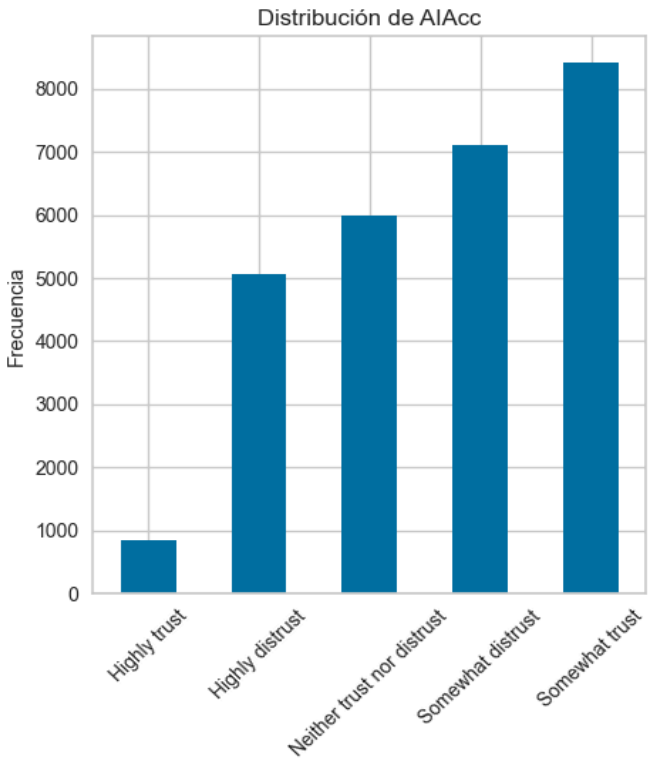
Por el teorema del límite central, podemos no comprobar la normalidad de la muestra gracias a que la media de la misma muestra tiende a una distribución normal con un n > 30, en este caso con 142 registros.

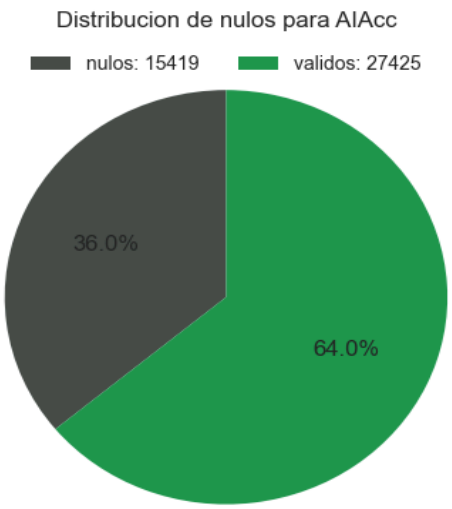
Así, usamos sklearn.stats para usar su algoritmo de t student a una cola planteando los valores dichos anteriormente, valor de referencia de 3 veces el SMVM y método ‘less’ en la opción de alternativa.

Finalmente, obtuvimos como resultado:
- Estadístico t: 6.259
- p-valor: 0.000

Por lo que dado el p-valor > 0.05, aceptamos la hipótesis nula diciendo que los desarrolladores que respondieron la encuesta de Argentina tienen significativamente un salario 3 veces mayor al Salario Mínimo, Vital y Móvil (SMVM).

- **Bivariada**: De aquellos desarrolladores senior que no confían en la IA, estos tienen mejor remuneración que aquellos que sí confían.



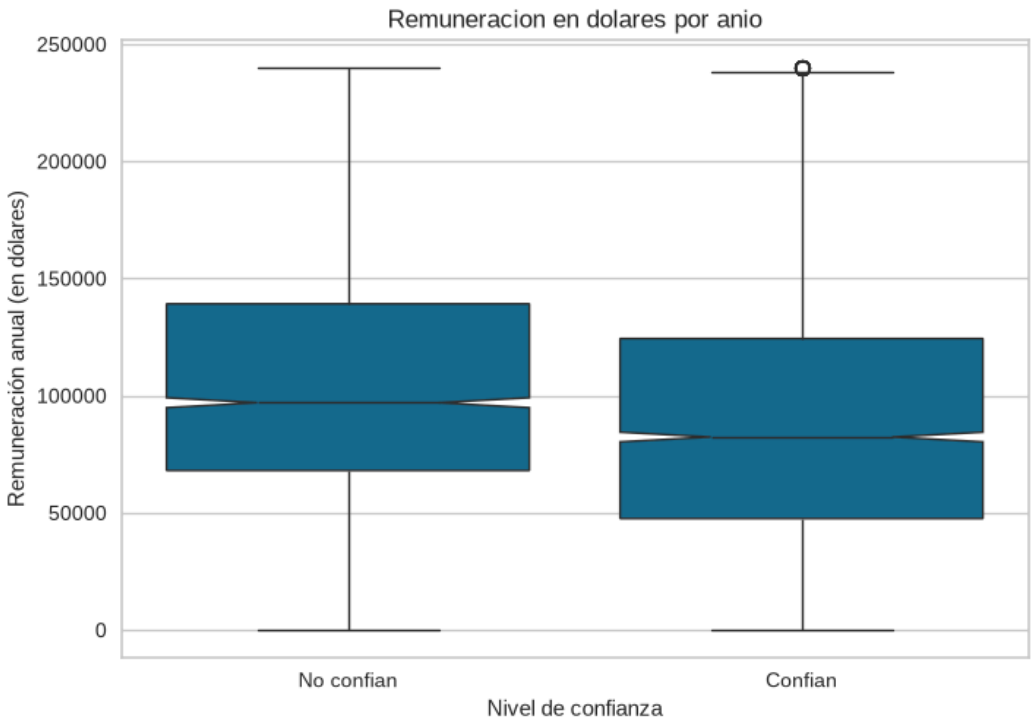


Tenemos que nuestra variable que describe dicha confianza en la Inteligencia Artificial presenta valores tales como `Confiar hasta cierto punto`, `Desconfiar hasta cierto punto`, `Ni confiar ni desconfiar`, `Alta desconfianza` y `Alta confianza`. Decidimos, que para tener una relación binaria de confianza o no confianza, mapear dichos valores a 0 o 1 según corresponda el siguiente criterio:

Highly distrust	0
Somewhat distrust	0
Neither trust nor distrust	nan
Somewhat trust	1
Highly trust	1

¿Por qué mapeamos `ni confiar ni desconfiar a nan`? Porque consideramos que es un punto gris que no nos interesa para este análisis. Además, trabajamos solo con los 27.425 válidos.

Así, ya que estamos trabajando con desarrolladores Senior, filtramos con 10 o más años de experiencia mediante **WorkExp** y organizamos los grupos separando en desarrolladores que no confían de los que no confían usando la variable **AIAcc** modificada anteriormente.



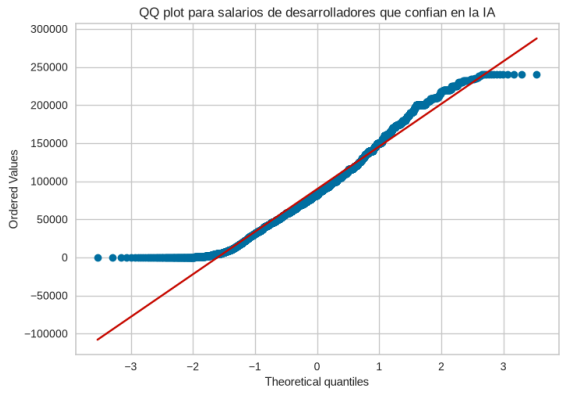
A simple vista pareciera existir diferencias significativas entre ambos grupos pero debemos probarlo estadísticamente.

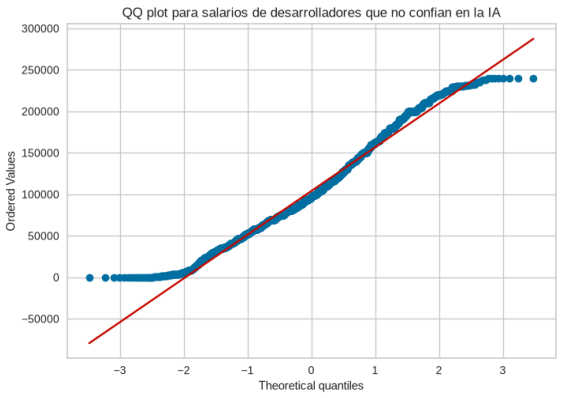
A continuación, realizamos un proceso de confirmación o no de los supuestos necesarios para los tests empezando por los paramétricos de mayor poder estadístico hasta los no paramétricos.

Primero, verificamos normalidad y homocedasticidad para ver si es que podemos un aplicar un test de student:

- Normalidad

  Graficamos un QQ-plot que nos ayuda a observar qué tan cerca de una distribución normal se encuentra nuestra variable.





A simple vista podemos ver que las colas se separan mucho de la distribución normal por lo que es probable que justamente no la sigan, igualmente comprobamos con Shapiro Wilks que declara como hipótesis nula la distribución normal, por lo que si p-valor < 0.05 decidimos que no tenemos distribución normal.

	Estadístico	p-value
Test de Shapiro para desarrolladores que no confían	0.980	0.000
Test de Shapiro para desarrolladores que confían	0.969	0.000

Definitivamente ninguna muestra sigue una distribución normal por lo que no podemos usar test de student. Vamos a comprobar la homocedasticidad a ver si podemos usar el test de Mann-Whitney.

- Homocedasticidad

En este caso, aplicamos directamente un test de Levene que declara como hipótesis nula la igualdad de varianzas, por lo que si p-valor < 0.05 decidimos que no se tiene dicha igualdad.

	Estadístico	p-value
Test de Levene	11.582	0.001

Definitivamente tampoco tenemos igualdad de varianzas, por lo que vamos a tener que usar el último test no paramétrico (Kruskal Wallis).

Sabemos que el test de Kruskal Wallis se basa en comparar que dos o más grupos contengan una distribución similar y la hipótesis nula de dicho test es la igualdad de distribuciones. Lo aplicamos mediante el paquete stats de sklearn.

	Estadístico	p-value
Test de Kruskal Wallis	112.840	0.000

Así, dado p-valor < 0.05, rechazamos la hipótesis nula y decimos que existe diferencia significativa en el salario anual en dólares entre desarrolladores que no confían en la IA y los que sí confían.

Finalmente pudimos comprobar estadísticamente que ambas muestras presentan diferencias significativas en la remuneración total anual en dólares. Como vimos antes en el box-plot, aquellos desarrolladores que no confían en la Inteligencia Artificial poseen dicha remuneración superior al grupo que sí confía.

¿Que nos puede llegar a decir dicho test? Que tal vez aquellos desarrolladores senior con una crítica superior a dichas herramientas puedan tomar decisiones de auditación que eviten errores o alucinaciones y mejoren su reconocimiento laboral para reflejarse en una mejor remuneración.

- Bivariada: Los años de experiencia profesional influyen en la confianza en la precisión de las herramientas de IA (Propuesta por cátedra).

  Determinamos dicha hipótesis como que existe una relación entre los años de experiencia laboral y la confianza en la precisión de las herramientas de IA.

  Tenemos que nuestra variable de confianza está representada mediante **AIAcc** como explicamos anteriormente contiene valores ordinales que son necesarios mapearlos numéricamente mediante el siguiente criterio:

Highly distrust	0
Somewhat distrust	1
Neither trust nor distrust	2
Somewhat trust	3
Highly trust	4

  Así, sabiendo que tenemos una variable ordinal y una cuantitativa, usamos la correlación de Spearman que nos permite plantear una prueba bilateral estableciendo:

  - HO: No existe una relación entre los años de experiencia laboral y la confianza en la precisión de las herramientas de IA (corr == 0).

  - H1: Existe una asociación entre ambas variables (corr != 0).

  Usamos el paquete spearman del paquete stats de sklearn donde declaramos a la hipótesis alternativa como ‘two sided’ justamente para que sea distinto a 0 y obtuvimos como resultado:

	Correlación	p-value
Test de Spearman	-0.024	0.00051

  Dado que p-valor < 0.05 rechazamos H0 (corr == 0) y aceptamos que existe una relación, cabe aclarar, entre los años de experiencia laboral y la confianza de precisión en las herramientas de IA.

- Multivariada: Los años de programación, la experiencia profesional, la satisfacción laboral, la edad, el tamaño de la organización, la cantidad de herramientas utilizadas en el trabajo y las tecnologías empleadas presentan una asociación significativa con el salario anual de los desarrolladores.

  Dado el análisis de reducción de dimensionalidad que desarrollamos anteriormente que observamos una especie de relación con los años de experiencia laboral, vamos a plantear un modelo de regresión lineal inicial con todas las variables posibles de ese análisis para posteriormente analizar y considerar cuales tienen significancia sobre la variable objetivo y cuáles no, donde la variable objetivo es **ConvertedCompYearly** (Salario anual en dólares).

  De igual manera que en los anteriores análisis realizamos mapeos que nos permitan transformar las variables cualitativas ordinales a numéricas para su correcto análisis.

  - AIAcc
  - Age
  - EdLevel
  - OrgSize

  Así, para eliminar el problema de las múltiples escalas entre variables y su mayor peso, estandarizamos las variables independientes mediante estandarización.

  Agregamos una constante a las variables independientes, declaramos el modelo mediante statsmodels y su funcion *fit* para obtener como resultado.

OLS Regression Results			
Dep. Variable:	ConvertedCompYearly	R-squared:	0.219
Model:	OLS	Adj. R-squared:	0.218
Method:	Least Squares	F-statistic:	215.2
Date:	Tue, 10 Nov 2026	Prob (F-statistic):	0.00
Time:	14:46:27	Log-Likelihood:	-1.2205e+05
No. Observations:	10001	AIC:	2.441e+05
Df Residuals:	9987	BIC:	2.442e+05
Df Model:	13	Covariance Type:	nonrobust

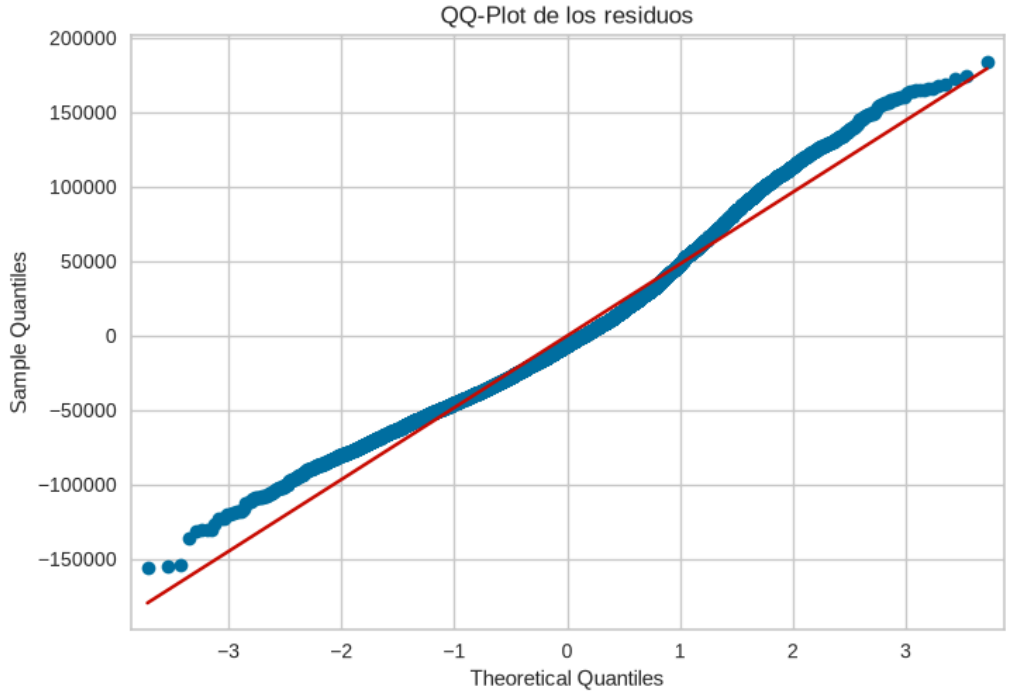
Variable	coef	std err	t	P>|t|	[0.025	0.975]
const	8.285e+04	482.983	171.537	0.000	8.19e+04	8.38e+04
YearsCode	8208.2130	1058.861	7.752	0.000	6132.632	1.03e+04
WorkExp	9575.7205	1265.955	7.564	0.000	7094.194	1.21e+04
JobSat	4343.7512	485.952	8.939	0.000	3391.188	5296.315
Age	3899.3559	953.138	4.091	0.000	2031.013	5767.699
EdLevel	1702.5646	496.719	3.428	0.001	728.895	2676.234
OrgSize	9040.1245	490.946	18.414	0.000	8077.772	1e+04
ToolCountWork	4664.2896	490.736	9.505	0.000	3702.349	5626.230
DatabaseChoice	-1084.6076	532.049	-2.039	0.042	-2127.531	-41.684
LanguageChoice	904.5790	486.142	1.861	0.063	-48.358	1857.516
PlatformChoice	4788.1154	519.011	9.225	0.000	3770.750	5805.481
WebframeChoice	-2488.3953	535.369	-4.648	0.000	-3537.827	-1438.963
DevEnvsChoice	1260.4872	515.393	2.446	0.014	250.213	2270.761
AIModelsChoice	724.6826	515.831	1.405	0.160	-286.449	1735.815

Prueba / Métrica	Valor	Prueba / Métrica	Valor
Omnibus:	573.832	Durbin-Watson:	1.966
Prob(Omnibus):	0.000	Jarque-Bera (JB):	676.497
Skew:	0.617	Prob(JB):	1.26e-147
Kurtosis:	3.317	Cond. No.:	5.39

Obtuvimos una variabilidad explicada del 21.9% que es sumamente baja y podemos deducir que no existe una relación entre el sueldo anual y el resto de variables que usamos en el análisis. Por otro lado, recordando el gráfico de t-sne y umap para el mismo análisis, tampoco vemos ningún tipo de patrón o relación que nos ayude a identificar correctamente el salario anual, por lo que concluimos que no existe ningún tipo de relación que logre representar correctamente al salario anual mediante las variables elegidas.

De igual manera, comprobamos los supuestos:

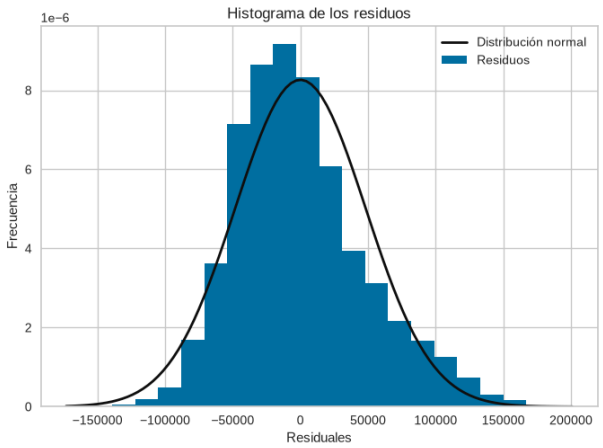
- Normalización



A simple vista podríamos intuir que no sigue una distribución normal pero comprobamos con Shapiro Wilks que nos otorga los resultados:

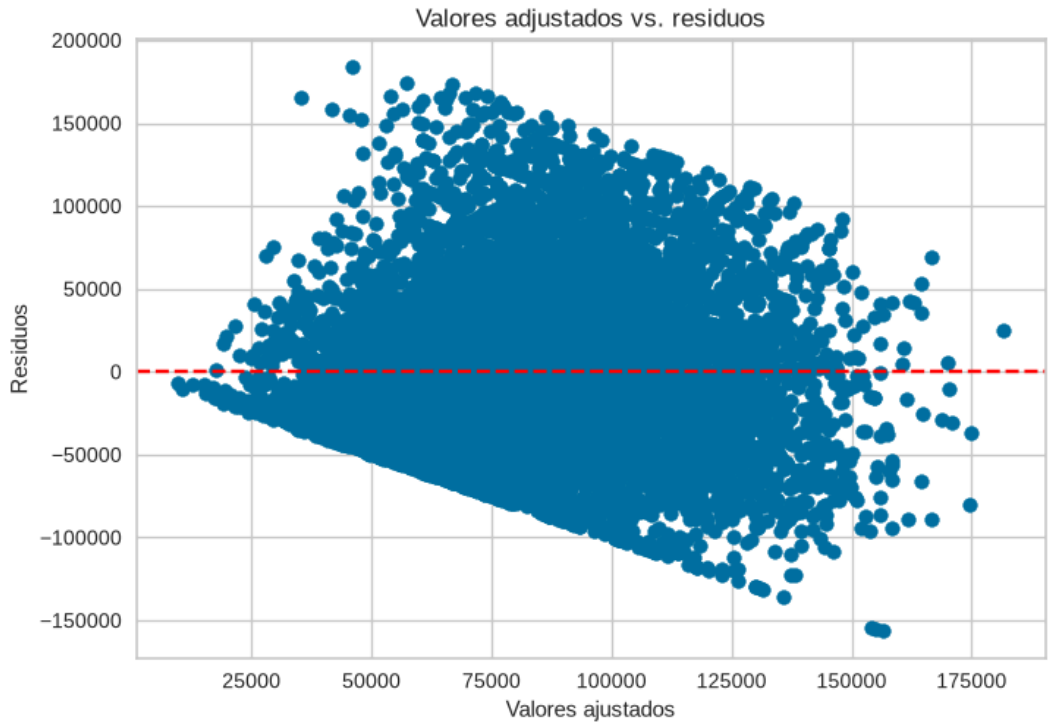
	Estadístico	p-value
Test de Shapiro para residuos	0.9747	0.000

Confirmamos que los residuos no siguen una distribución normal aunque seguimos comprobando el resto de supuestos.



- Comportamiento en banda

  Mediante un diagrama de dispersión entre los valores ajustados y sus residuos podemos observar si se cumple la homocedasticidad.



  Claramente no vemos un comportamiento aleatorio a lo largo del cero, por lo que tampoco cumplimos la homocedasticidad.

- Autocorrelación

  Mediante el estadístico de Durbin Watson medimos la presencia de autocorrelación en los residuos de un modelo donde su rango oscila entre (0, 4) y un valor cercano a 2 indica que no hay autocorrelación significativa.

  En nuestro caso, la medición arrojó 1.966 por lo que no tenemos autocorrelación significativa.

- Multivariada: Están los distintos niveles de satisfacción en los distintos aspectos del trabajo actual relacionados a la consideración de un cambio de rol o de carrera (propuesta por cátedra).

  Tenemos que la variable que almacena la información sobre un posible o hecho cambio de rol / carrera está dada por **NewRole** que es de tipo cualitativa ordinal conteniendo valores como que no lo considero, lo considero levemente, lo considero seriamente, lo realizó involuntariamente. Así, vamos a tomar como verdadero que considero o realizó dicho cambio de forma voluntaria y será nuestra variable objetivo.

I have neither considered or transitioned into a new career or industry	0
I have somewhat considered changing my career and/or the industry I work in	1
I have strongly considered changing my career and/or the industry I work in	1
I have transitioned into a new career and/or industry voluntarily	1
I have transitioned into a new career and/or industry involuntarily	0

  Además, tomamos como variables independientes las siguientes:

  - **JobSat**
  - **JobSatPoints_1**
  - **JobSatPoints_2**
  - **JobSatPoints_3**
  - **JobSatPoints_4**
  - **JobSatPoints_5**
  - **JobSatPoints_6**
  - **JobSatPoints_7**
  - **JobSatPoints_8**
  - **JobSatPoints_9**
  - **JobSatPoints_10**
  - **JobSatPoints_11**
  - **JobSatPoints_13**
  - **JobSatPoints_14**
  - **JobSatPoints_15**
  - **JobSatPoints_16**

Estandarizamos dichas variables independientes, añadimos el intercepto y creamos un modelo que es entrenado mediante *fit* donde su resultado es:

Logit Regression Results			
Dep. Variable:	NewRole	No. Observations:	19591
Model:	Logit	Df Residuals:	19574
Method:	MLE	Df Model:	16
Date:	Tue, 10 Nov 2026	Pseudo R-squ.:	0.05435
Time:	22:38:19	Log-Likelihood:	-12835.
converged:	True	LL-Null:	-13572.
Covariance Type:	nonrobust	LLR p-value:	1.067e-304

Variable	coef	std err	z	P>|z|	[0.025	0.975]
const	0.0658	0.015	4.427	0.000	0.037	0.095
JobSat	-0.5697	0.016	-35.306	0.000	-0.601	-0.538
JobSatPoints_1	0.0622	3.22e+05	1.93e-07	1.000	-6.32e+05	6.32e+05
JobSatPoints_2	-0.0137	3.16e+05	-4.35e-08	1.000	-6.19e+05	6.19e+05
JobSatPoints_3	0.0212	3.22e+05	6.58e-08	1.000	-6.31e+05	6.31e+05
JobSatPoints_4	-0.0398	3.27e+05	-1.22e-07	1.000	-6.4e+05	6.4e+05
JobSatPoints_5	-0.0581	3.07e+05	-1.89e-07	1.000	-6.01e+05	6.01e+05
JobSatPoints_6	-0.0189	3.27e+05	-5.78e-08	1.000	-6.41e+05	6.41e+05
JobSatPoints_7	-0.0379	3.36e+05	-1.13e-07	1.000	-6.59e+05	6.59e+05
JobSatPoints_8	0.0633	3.55e+05	1.78e-07	1.000	-6.96e+05	6.96e+05
JobSatPoints_9	0.0274	3.35e+05	8.19e-08	1.000	-6.57e+05	6.57e+05
JobSatPoints_10	-0.0193	3.31e+05	-5.83e-08	1.000	-6.48e+05	6.48e+05
JobSatPoints_11	-0.0028	3.53e+05	-7.99e-09	1.000	-6.92e+05	6.92e+05
JobSatPoints_13	0.0215	3.05e+05	7.03e-08	1.000	-5.98e+05	5.98e+05
JobSatPoints_14	-0.0046	3.12e+05	-1.46e-08	1.000	-6.11e+05	6.11e+05

Variable	coef	std err	z	P>|z|	[0.025	0.975]
JobSatPoints_15	-0.0191	1.54e+05	-1.24e-07	1.000	-3.02e+05	3.02e+05
JobSatPoints_16	0.0022	3.5e+05	6.26e-09	1.000	-6.86e+05	6.86e+05

Al analizar los resultados obtenidos sobre los 19.591 registros válidos, lo primero que miramos es la significancia global del modelo mediante el p-valor asociado al estadístico LLR (*LLR p-value*). Dicho valor resultó significativamente bajo ($1,067 \times 10^{-304} \ll 0,05$), lo que nos indica que el modelo en su conjunto es válido frente al modelo nulo. Sin embargo, al observar el *Pseudo R-squared* vemos que apenas alcanza un **5,44%** ($0,05435$), un porcentaje sumamente bajo que nos demuestra que estas variables por sí solas no logran explicar la variabilidad de **NewRole** ni predecir de manera razonable el cambio de carrera.

Si pasamos a evaluar cuánta presencia tiene cada variable independiente en la predicción (buscando un p-valor menor a $0,05$ para una significancia del 5%), nos encontramos con dos comportamientos bien marcados:

- **JobSat (Satisfacción laboral general):** Como nos dio un p-valor muy bajo ($0,000 < 0,05$), se confirma que efectivamente aporta a la definición de la variable respuesta y guarda una asociación estadísticamente significativa con ella. Además, su coeficiente resultó negativo ($-0,5697$, con un intervalo de confianza entre $-0,601$ y $-0,538$), algo que tiene mucho sentido pensando en el problema: cuanto más satisfecho está un desarrollador en su puesto actual, menor es la probabilidad de que considere o realice voluntariamente un cambio de rol o de industria (**NewRole = 1**).

- **JobSatPoints_1 a JobSatPoints_16 (Aspectos específicos del trabajo):** Todas estas variables arrojaron un p-valor igual a $1,000$ (muy por encima del umbral de $0,05$) acompañado de errores estándar desproporcionadamente altos, en torno a 3×10^{5}. Esto nos indica que ninguna de ellas resulta estadísticamente significativa ni suma capacidad explicativa al modelo por encima de la satisfacción general.

Como conclusión, la hipótesis planteada se cumple sólo de forma parcial: podemos asegurar estadísticamente que una menor satisfacción laboral general (**JobSat**) predispone al desarrollador a buscar un nuevo rol, pero no hay evidencia suficiente para afirmar que los niveles de satisfacción en los distintos aspectos particulares del trabajo (**JobSatPoints**) influyan en dicha decisión.

9. Conclusión

A lo largo de este trabajo analizamos la Encuesta para Desarrolladores de 2025 de Stack Overflow con el objetivo de comprender las características laborales de los desarrolladores, las tecnologías que emplean y su relación con las herramientas de Inteligencia Artificial. Para lograrlo, la etapa de limpieza, codificación y filtrado de valores atípicos mediante el criterio del rango intercuartílico fue determinante, ya que permitió depurar un conjunto de datos con alta proporción de valores nulos y sesgos extremos —principalmente en las remuneraciones y en el conteo de herramientas— para trabajar sobre distribuciones representativas.

A partir del análisis exploratorio y la reducción de dimensionalidad mediante PCA, observamos que los años de experiencia laboral, los años programando y la edad están fuertemente correlacionados y definen un eje claro de *seniority*. Sin embargo, el hecho de que la varianza se reparta entre múltiples componentes demostró que aspectos como el tamaño de la organización, el stack tecnológico y la percepción sobre la IA aportan información independiente entre sí y no admiten una reducción drástica de dimensiones sin pérdida de información.

Finalmente, el contraste de hipótesis permitió validar estadísticamente las tendencias detectadas en la etapa visual. Comprobamos que los desarrolladores que no ven a la IA como una amenaza superan en promedio los 5 años de experiencia y que una mayor trayectoria profesional se asocia con una postura más crítica hacia la precisión de estas herramientas, registrándose incluso mejores salarios entre los perfiles *senior* que desconfían de los resultados de la IA. Por su parte, los análisis multivariados reflejaron que, aunque la trayectoria y la satisfacción laboral general tienen un peso estadísticamente significativo sobre el salario anual y la decisión de cambiar de carrera, estas variables por sí solas explican una porción baja de la variabilidad total, dejando en evidencia que tanto la remuneración como la rotación laboral dependen de factores adicionales a los capturados de forma lineal.